Модификации метода анализа сингулярного спектра для анализа временных рядов

Погребников Николай Вадимович, гр. 21.Б04-мм

Санкт-Петербургский государственный университет
Прикладная математика и информатика
Вычислительная стохастика и статистические модели

Научный руководитель — доктор физико-математических наук,
Н. Э. Голяндина
Рецензент — лектор, университет Кардиффа А. Н. Пепелышев

Санкт-Петербург, 2025

Введение

$\mathsf{X} = (x_1, \ldots, x_N)$ – временной ряд длины N, $x_i \in \mathbb{R}$.
$\mathsf{X} = \mathsf{X}^{(\text{Trend})} + \mathsf{X}^{(\text{Periodics})} + \mathsf{X}^{(\text{Noise})}$, где:

- $\mathsf{X}^{(\text{Trend})}$ – тренд, медленно меняющаяся компонента;
- $\mathsf{X}^{(\text{Periodics})}$ – сумма периодических компонент;
- $\mathsf{X}^{(\text{Noise})}$ – шум, случайная составляющая.

Методы:
`SSA` – метод, позволяющий раскладывать временной ряда в сумму интерпретируемых компонент (Golyandina, Nekrutkin и Zhigljavsky 2001);
`GSSA` – модификация `SSA` на основе добавления весов (Gu и др. 2024);
`CiSSA` – модификация `SSA` на основе циркулярной матрицы (Bogalo, Poncela и Senra 2021).
Задача: Описание модификаций в контексте теории `SSA`, сравнение алгоритмов, реализация их на языке R.

Метод SSA. Алгоритм

$\mathsf{X} = \mathsf{X} = \mathsf{S} + \mathsf{X}^{(\mathrm{Noise})} = \mathsf{S}^{(1)} + \mathsf{S}^{(2)} + \mathsf{X}^{(\mathrm{Noise})}$ — временной ряд.
S – сигнал, $\mathsf{S}^{(1)}$ и $\mathsf{S}^{(2)}$ – компоненты сигнала. L – длина окна.
r_1 и r_2 – ранги компонент сигнала, $r = r_1 + r_2$.

Алгоритм SSA:

1. **Построение траекторной матрицы:**
   $\mathbf{X} = \mathcal{T}_{\mathtt{SSA}}(\mathsf{X}) = [\mathsf{X}_1 : \ldots : \mathsf{X}_K]$, $\mathsf{X}_i = (x_i, \ldots, x_{i+L-1})^T$,
   $1 \le i \le K, \quad K = N - L + 1.$
2. **Сингулярное разложение (SVD)** траекторной матрицы:
   $$\mathbf{X} = \sum_{i=1}^{d} \sqrt{\lambda_i} U_i V_i^T = \sum_{i=1}^{d} \mathbf{X}_i,\ d = \mathsf{rank}(\mathbf{X}).$$
3. **Группировка** матриц разложения:
   $$\mathbf{S}^{(j)} = \sum_{i \in I_j} \mathbf{X}_i,\ \mathrm{rank}(\mathbf{S}^{(j)}) = r_j,\ j = 1, 2.$$
   $$\mathbf{X} = \mathbf{S}^{(1)} + \mathbf{S}^{(2)} + \mathbf{X}^{(\mathrm{Noise})}.$$
4. **Восстановление** ряда: $\mathsf{X} = \tilde{\mathsf{S}}^{(1)} + \tilde{\mathsf{S}}^{(2)} + \tilde{\mathsf{X}}_{\mathrm{Noise}}$.

Многомерные варианты SSA

Нужно переопределить вход и $\mathcal{T}$.

MSSA. Параметры: $L \le \max(N_p)$.

- $\mathsf{X} = \{\mathsf{X}^{(p)} = \left(x_j^{(p)}\right)_{j=1}^{N_p},\ p = 1, \dots, s\}$,
- $\mathcal{T}_{\text{MSSA}}(\mathsf{X}) = \mathbf{X} = [\mathbf{X}_1^{(1)} : \dots : \mathbf{X}_{K_1}^{(1)} : \dots : \mathbf{X}_1^{(s)} : \dots : \mathbf{X}_{K_s}^{(s)}] = [\mathbf{X}^{(1)} : \dots : \mathbf{X}^{(s)}]$, $\mathbf{X}^{(p)} = \mathcal{T}_{\text{SSA}}(\mathsf{X}^{(p)})$

2D-SSA. Параметры: (L_x, L_y), где $1 \le L_x \le N_x$, $1 \le L_y \le N_y$.

- $\mathsf{X} = (x_{ij})_{i,j=1}^{N_x,N_y}$, где $N_x \times N_y$ — размер массива.
- Из X выделяются все возможные подматрицы $\mathsf{X}_{k,l}^{(L_x,L_y)}$.
- Каждая подматрица $\mathsf{X}_{k,l}^{(L_x,L_y)}$ преобразуется в столбец: $\mathbf{X}_{k+(l-1)K_x} = \text{vec}(\mathsf{X}_{k,l}^{(L_x,L_y)})$.
- $\mathcal{T}_{\text{2D-SSA}}(\mathsf{X}) = \mathbf{X} = [\mathbf{X}_1 : \dots : \mathbf{X}_{K_xK_y}]$.

Вложенный вариант SSA

$$\mathsf{X} = \mathsf{S} + \mathsf{X}^{(\mathrm{Noise})} = \mathsf{S}^{(1)} + \mathsf{S}^{(2)} + \mathsf{X}^{(\mathrm{Noise})}.$$

Определение 1 (Golyandina и Shlemov 2015)

Вложенный вариант SSA — двухэтапный метод:

1. $\tilde{\mathsf{S}}$ – результат SSA для первых r слагаемых SVD.
2. Применение другого метода к $\tilde{\mathsf{S}}$ для улучшения разделимости: $\tilde{\mathsf{S}} = \tilde{\mathsf{S}}^{(1)} + \tilde{\mathsf{S}}^{(2)}$.

SSA EOSSA (Golyandina, Dudnik и Shlemov 2023) – вложенный вариант SSA.

Метод GSSA. Алгоритм

$\mathsf{X} = \mathsf{X} = \mathsf{S} + \mathsf{X}^{(\mathrm{Noise})} = \mathsf{S}^{(1)} + \mathsf{S}^{(2)} + \mathsf{X}^{(\mathrm{Noise})}$ — временной ряд.

Параметры L и $\alpha \geq 0$.

$$\boldsymbol{w}^{(a)} = (w_1, w_2, \ldots, w_L) = \left(\left| \sin\left(\frac{\pi n}{L+1} \right) \right|^{\alpha} \right), \quad n = 1, 2, \ldots, L.$$

Шаг 1 алгорима GSSA:

$$\mathbf{X}^{(\alpha)} = \mathcal{T}_L^{(\alpha)}(\mathsf{X}) = [\mathsf{X}_1^{(\alpha)} : \ldots : \mathsf{X}_K^{(\alpha)}],$$

$$\mathsf{X}_i^{(\alpha)} = (w_1 x_{i-1}, \ldots, w_L x_{i+L-2})^{\mathrm{T}}, \; 1 \leq i \leq K.$$

Шаги 2-4: аналогичны SSA.

Замечание 1

При $\alpha = 0$, GSSA — в точности базовый алгоритм SSA.

Замечание 2

$\boldsymbol{w}^{(a)}$ могут иметь другой вид.

Сравнение SSA и GSSA. Линейные фильтры

$\mathsf{X} = (x_1, \ldots, x_N)$. Восстановление $\widetilde{\mathsf{X}}^{(i)} = (\tilde{x}_1, \ldots, \tilde{x}_N)$:
для SSA по $\mathbf{X}_i = \sqrt{\lambda} U V^T$, $U = (u_1, \ldots, u_L)^T$;
для GSSA по $\mathbf{X}_i = \sqrt{\lambda^{(\alpha)}} U^{(\alpha)} V^{(\alpha)T}$, $U^{(\alpha)} = (u_1^{(\alpha)}, \ldots, u_L^{(\alpha)})^T$.

Запись SSA через линейный фильтр для средних точек:

$$\widetilde{x}_s = \sum_{j=-(L-1)}^{L-1} \left(\sum_{k=1}^{L-|j|} u_k u_{k+|j|} / L \right) x_{s-j}, \quad L \le s \le K.$$

Аналогичное представление для GSSA:

$$\widetilde{x}_s = \sum_{j=-(L-1)}^{L-1} \left(\sum_{k=1}^{L-|j|} u_k^{(\alpha)} u_{k+|j|}^{(\alpha)} w_k \Big/ \sum_{i=1}^{L} w_i \right) x_{s-j}, \quad L \le s \le K.$$

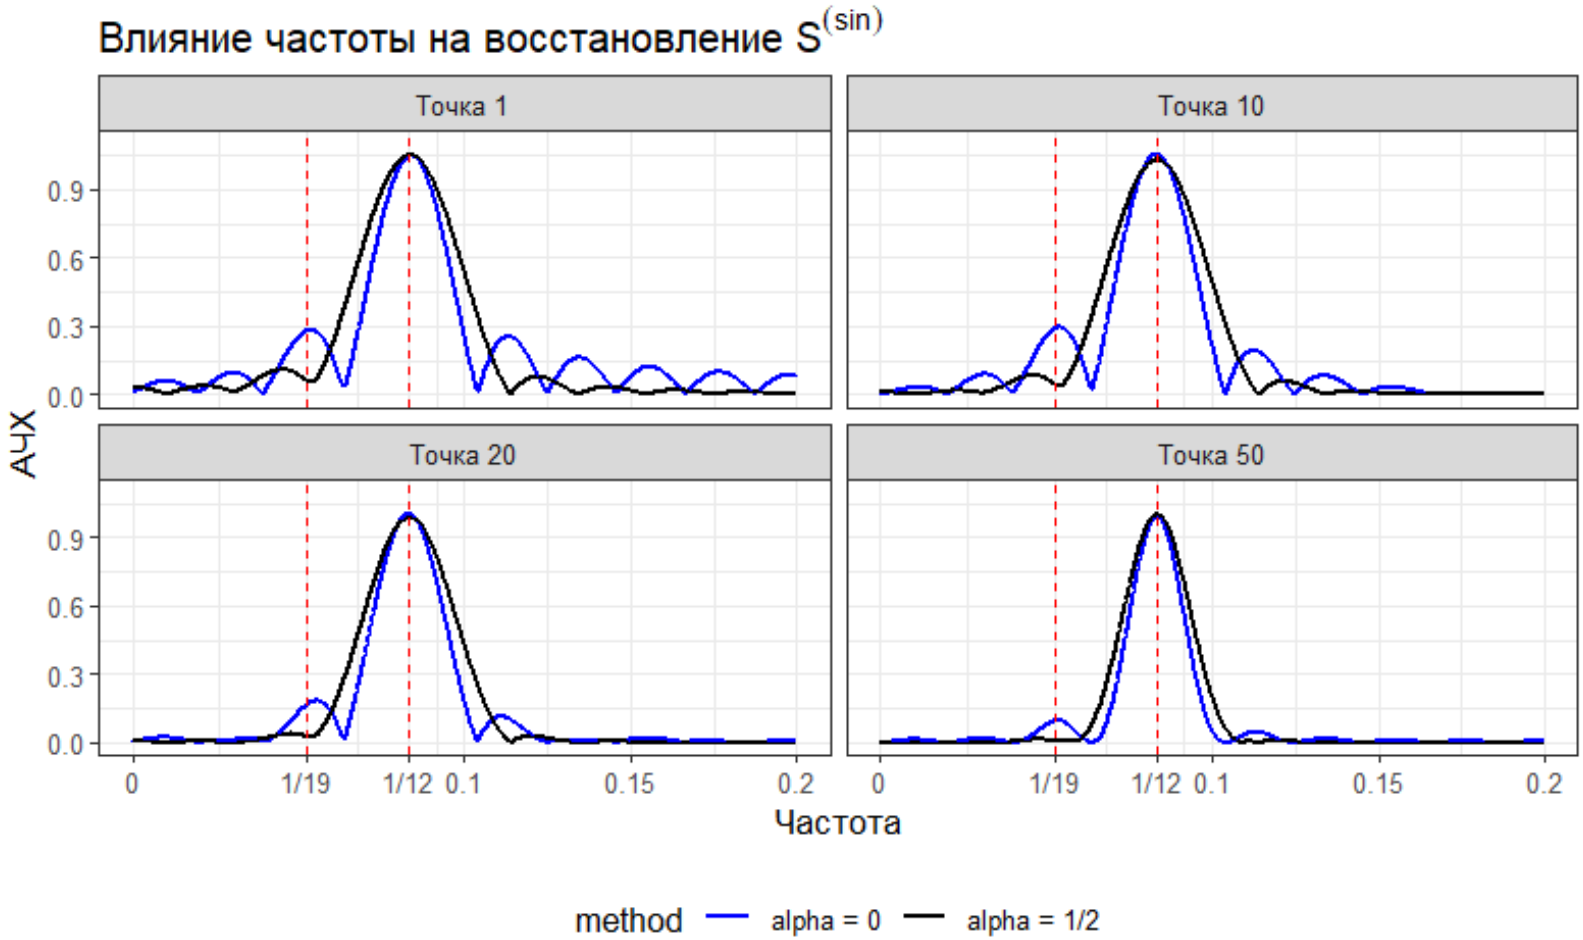
Замечание 1

Представление через линейные фильтры можно получить и для остальных точек ряда.

Сравнение SSA и GSSA. Пример

$$\mathsf{X} = \mathsf{S}^{(\sin)} + \mathsf{S}^{(\cos)} + \mathsf{X}^{(\text{Noise})} =$$
$$\left\{\sin\left(\frac{2\pi}{12}n\right) + \frac{1}{2}\cos\left(\frac{2\pi}{19}n\right) + \varepsilon_n,\ n = 1:191\right\},\ \varepsilon_n \sim \mathrm{N}(0, 0.1^2).$$

Группировка: $\mathbf{S}^{(\sin)} = \mathbf{X}_1 + \mathbf{X}_2$, $\mathbf{S}^{(\cos)} = \mathbf{X}_3 + \mathbf{X}_4$. $L = 48$.



GSSA. Вывод: вложенный вариант SSA + GSSA

Таблица 1: $\mathsf{X} = \mathsf{S}^{(\sin)} + \mathsf{S}^{(\cos)} + \mathsf{X}^{(\mathrm{Noise})}$, MSE оценок.

Метод/Ошибка	$\mathsf{S}^{(\sin)}$	$\mathsf{S}^{(\cos)}$	X
SSA	5.68e-03	5.44e-03	**7.48e-04**
GSSA, $\alpha = 0.5$	**1.21e-03**	**1.25e-03**	1.04e-03
SSA + GSSA, $\alpha = 0.5$	**1.06e-03**	**1.12e-03**	**7.48e-04**

Применяя SSA для выделения сигнала, затем GSSA для разделения компонент, получается наилучший результат.

Метод CiSSA. Алгоритм

$\mathsf{X} = \mathsf{S} + \mathsf{X}^{(\mathrm{Noise})} = \mathsf{S}^{(1)} + \mathsf{S}^{(2)} + \mathsf{X}^{(\mathrm{Noise})}$. L – длина окна.

Алгоритм CiSSA:

1. **Построение траекторной матрицы:** как в SSA.
2. $l = 1 : L$,
   $U_l = L^{-1/2}(u_{l,1}, \ldots, u_{l,L})$, $u_{l,j} = \exp\left(-\mathrm{i}2\pi(j-1)\frac{l-1}{L}\right)$.
   Элементарное разложение: $\omega_k = \frac{k-1}{L}$, $k = 1 : \lfloor \frac{L+1}{2} \rfloor$

   $$\mathbf{X}_{\omega_1} = U_1 U_1^H \mathbf{X}, \quad \mathbf{X}_{\omega_k} = U_k U_k^H \mathbf{X} + U_{L+2-k} U_{L+2-k}^H \mathbf{X};$$
   $$\mathbf{X}_{\omega_{\frac{L}{2}+1}} = U_{\frac{L}{2}+1} U_{\frac{L}{2}+1}^H \mathbf{X}, \text{ если } \quad L \bmod 2 = 0,$$

   Разложение: $\mathbf{X} = \sum_{k=1}^{d} \mathbf{X}_{\omega_k}$, $d = \lfloor \frac{L+1}{2} \rfloor$ (или $\frac{L}{2}+1$).
3. !!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!! **Группировка** по частотам:
   $\bigsqcup_{j=1}^{2} \Omega_j = \bigsqcup_{j=1}^{2} \left[\omega_j^{(l)}, \omega_j^{(r)}\right] = [0, 0.5]$. $\mathbf{S}^{(j)} = \sum_{\omega_k \in \Omega_j} \mathbf{X}_{\omega_k}$.
4. **Диагональное усреднение:** как в SSA.

Метод CiSSA. Особенности

1. Простая автоматическая группировка по заданному набору частот.
2. SSA: базис адаптивный (зависит от X, L, N).
   CiSSA: базис фиксированный (зависит от L, N).
3. Сложность при подборе L для попадания в сетку частот.

Метод CiSSA. Набор примеров и параметров

Примеры:

1. $\mathsf{X} = \mathsf{S}^{(\sin)} + \mathsf{S}^{(\cos)} + \mathsf{X}^{(\text{Noise})} =$
   $= \left\{\sin(\frac{2\pi}{12}n) + \frac{1}{2}\cos(\frac{2\pi}{3}n) + \varepsilon_n,\ n = 1:191\right\}.$
2. $\mathsf{X} = \mathsf{S}^{(e\cdot\sin)} + \mathsf{S}^{(e\cdot\cos)} + \mathsf{X}^{(\text{Noise})} =$
   $= \left\{e^{\frac{n}{200}}\sin(\frac{2\pi}{12}n) + e^{\frac{n}{100}}\cos(\frac{2\pi}{3}n) + \varepsilon_n,\ n = 1:191\right\}.$

Параметры:

- $\varepsilon_n \sim N(0, 0.1^2)$, $\delta = 1/191$.
- `CiSSA`: $L = 12, 48, 96, 97$.
  1. $\Omega_{\sin} = \left[\frac{1}{12} \pm 6\delta\right]$, $\Omega_{\cos} = \left[\frac{1}{3} \pm 6\delta\right]$;
  2. $\Omega_{e\cdot\sin} = \left[\frac{1}{12} \pm 6\delta\right]$, $\Omega_{e\cdot\cos} = \left[\frac{1}{3} \pm 6\delta\right]$.
- `SSA EOSSA`: $L = 96$, $r = 4$.
  1. $\Omega_{\sin} = \left[\frac{1}{12} \pm 6\delta\right]$, $\Omega_{\cos} = \left[\frac{1}{3} \pm 6\delta\right]$;
  2. $\Omega_{e\cdot\sin} = \left[\frac{1}{12} \pm 6\delta\right]$, $\Omega_{e\cdot\cos} = \left[\frac{1}{3} \pm 6\delta\right]$.
- `SSA`: $L = 96$.
  1. $\mathbf{S}^{(\sin)} = \mathbf{X}_1 + \mathbf{X}_2$, $\mathbf{S}^{(\cos)} = \mathbf{X}_3 + \mathbf{X}_4$;
  2. $\mathbf{S}^{(e\cdot\sin)} = \mathbf{X}_1 + \mathbf{X}_2$, $\mathbf{S}^{(e\cdot\cos)} = \mathbf{X}_3 + \mathbf{X}_4$.

Метод CiSSA. Сравнение с SSA 1

Пример 1: $\mathsf{X} = \mathsf{S}^{(\sin)} + \mathsf{S}^{(\cos)} + \mathsf{X}^{(\mathrm{Noise})}$.

Метод	Параметры	$\mathrm{MSE}\left(\mathsf{S}^{(\sin)}\right)$	$\mathrm{MSE}\left(\mathsf{S}^{(\cos)}\right)$	$\mathrm{MSE}\left(\mathsf{X}\right)$
CiSSA	$L = 97$	3.5e-03	7.6e-03	9.6e-03
CiSSA	$L = 12$	1.1e-03	1.1e-03	2.3e-03
CiSSA	$L = 48$	**9.9e-04**	1.0e-03	2.0e-03
CiSSA	$L = 96$	**8.7e-04**	**9.2e-04**	1.8e-03
SSA EOSSA	$L = 96$	**4.2e-04**	**4.4e-04**	**8.6e-04**
SSA EOSSA	$L = 97$	**4.3e-04**	**4.7e-04**	**9.1e-04**
SSA	$L = 96$	**3.4e-04**	**2.9e-04**	**6.3e-04**
SSA	$L = 97$	**3.4e-04**	**2.9e-04**	**6.3e-04**

- CiSSA: непопадание в сетку частот даёт наихудший результат, иначе **при росте** L разделение **улучшается**.
- SSA: на порядок лучше разделяет сигнал от шума, чем CiSSA.

Метод CiSSA. Сравнение с SSA 2

Пример 2: $\mathsf{X} = \mathsf{S}^{(e\cdot\sin)} + \mathsf{S}^{(e\cdot\cos)} + \mathsf{X}^{(\mathrm{Noise})}$.

Метод	Параметры	$\mathrm{MSE}\left(\mathsf{S}^{(e\cdot\sin)}\right)$	$\mathrm{MSE}\left(\mathsf{S}^{(e\cdot\cos)}\right)$	$\mathrm{MSE}\left(\mathsf{X}\right)$
`CiSSA`	$L = 97$	1.4e-02	2.7e-01	2.5e-01
`CiSSA`	$L = 12$	1.2e-03	2.2e-03	3.3e-03
`CiSSA`	$L = 48$	2.1e-03	2.3e-02	2.3e-02
`CiSSA`	$L = 96$	6.3e-03	8.4e-02	8.4e-02
`SSA EOSSA`	$L = 96$	**4.0e-04**	**4.6e-04**	**8.6e-04**
`SSA EOSSA`	$L = 96$	**3.9e-04**	**3.6e-04**	**7.6e-04**
`SSA`	$L = 96$	**4.5e-04**	**3.7e-04**	**7.0e-04**
`SSA`	$L = 96$	**5.7e-04**	**5.3e-04**	**6.9e-04**

- `CiSSA`: непопадание в сетку частот также даёт наихудший результат, иначе **при росте** L разделение **ухудшается**.
- `SSA`: на порядок лучше разделяет сигнал от шума, чем `CiSSA`.

Метод CiSSA. Выводы

Метод FSSA. Алгоритм

$\mathsf{X} = \{x_j(s_k)\}_{j=1,\dots,N}^{k=1,\dots,M}$ – матрица временного ряда, $s_k \in [0,1]$.

L – длина окна, $\{\nu_i(s) \in \mathbb{H}\}_{i=1}^{d}$ – базис.

Алгоритм FSSA:

1. **Преобразование:** $x_j(s) = \sum\limits_{i=1}^{d} a_{i,j}\nu_i(s)$.
2. **Построение траекторной матрицы:**
   $\mathbf{X}(s) = [\boldsymbol{x}_1(s), \dots, \boldsymbol{x}_K(s)]$, $K = N - L + 1$,
   $\boldsymbol{x}_j(s) = (x_j(s), \dots, x_{j+L-1}(s))^\top, \quad j = 1, \dots, K$.
3. **Разложение SVD:** $\mathbf{X}(s) = \sum\limits_{i=1}^{Ld} \mathbf{X}_i(s) = \sum\limits_{i=1}^{Ld} \sqrt{\lambda_i} v_i \otimes \boldsymbol{\psi}_i(s)$.
4. **Группировка** матриц разложения:
   $\mathbf{S}^{(j)}(s) = \sum\limits_{i \in I_j} \mathbf{X}_i(s)$, $j = 1, 2$.
   $\mathbf{X}(s) = \mathbf{S}^{(1)}(s) + \mathbf{S}^{(2)}(s) + \mathbf{X}^{(\mathrm{Noise})}(s)$.
5. **Восстановление** ряда: $\mathsf{X}(s) = \tilde{\mathsf{S}}^{(1)}(s) + \tilde{\mathsf{S}}^{(2)}(s) + \tilde{\mathsf{X}}_{\mathrm{Noise}}(s)$.

Метод FSSA. Сравнение с MSSA и 2D-SSA

Таблица 2: Результаты сравнения методов 2d-SSA, MSSA и FSSA при различных параметрах ω и N.

ω	N	$L = 20$			$L = 30$			$L = 40$		
		2D-SSA	MSSA	FSSA	2D-SSA	MSSA	FSSA	2D-SSA	MSSA	FSSA
0.10	50	0.009	0.028	0.009	0.010	0.026	0.010	0.011	0.021	0.013
	100	0.009	0.027	0.008	0.007	0.023	0.006	0.006	0.020	0.006
	150	0.008	0.027	0.005	0.007	0.023	0.006	0.006	0.019	0.005
	200	0.007	0.026	0.005	0.006	0.022	0.005	0.006	0.019	0.005
0.25	50	0.009	0.029	0.010	0.009	0.023	0.010	0.010	0.021	0.014
	100	0.008	0.027	0.006	0.008	0.024	0.007	0.006	0.020	0.007
	150	0.007	0.026	0.005	0.007	0.021	0.006	0.006	0.020	0.006
	200	0.008	0.026	0.005	0.007	0.022	0.005	0.006	0.019	0.005

Итоги

GSSA улучшает разделимость компонент временного ряда введением весов, интерпретируя SSA как линейные адаптивные фильтры. Предложена вложенная модификация, объединяющая преимущества обоих алгоритмов.

CiSSA заменяет адаптивный базис SSA фиксированным, упрощая выделение компонент в заданных частотах. Проблемы с амплитудно-модулированными гармониками и выбором окна снижают эффективность. Базовый SSA с автоматической идентификацией обеспечивает схожую или лучшую точность.

FSSA ориентирован на двумерные данные, сравним по точности с 2D-SSA. FSSA учитывает регулярное поведение по непрерывному параметру, что игнорировалось в сравнении с MSSA.

Список литературы I

- Bogalo, J., P. Poncela и E. Senra (2021). «Circulant singular spectrum analysis: A new automated procedure for signal extraction». В: *Signal Processing* 179. 107824. ISSN: 0165-1684. DOI: https://doi.org/10.1016/j.sigpro.2020.107824.
- Golyandina, N., P. Dudnik и A. Shlemov (2023). «Intelligent identification of trend components in singular spectrum analysis». В: *Algorithms* 16.7. 353. DOI: 10.3390/a16070353.
- Golyandina, N., V. Nekrutkin и A. Zhigljavsky (2001). *Analysis of Time Series Structure: SSA and Related Techniques*. Chapman и Hall/CRC.

Список литературы II

- Golyandina, N. и A. Shlemov (2015). «Variations of singular spectrum analysis for separability improvement: non-orthogonal decompositions of time series». В: *Statistics and Its Interface* 8.3, с. 277—294. ISSN: 1938-7997. DOI: 10.4310/sii.2015.v8.n3.a3.
- Gu, J. и др. (2024). «Generalized singular spectrum analysis for the decomposition and analysis of non-stationary signals». В: *Journal of the Franklin Institute* 361.6. 106696. ISSN: 0016-0032. DOI: https://doi.org/10.1016/j.jfranklin.2024.106696.