

Санкт-Петербургский государственный университет

**ПОГРЕБНИКОВ Николай Вадимович**

**Выпускная квалификационная работа**

**МОДИФИКАЦИИ МЕТОДА АНАЛИЗА СИНГУЛЯРНОГО СПЕКТРА ДЛЯ  
АНАЛИЗА ВРЕМЕННЫХ РЯДОВ**

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа 21.Б04-мм «Прикладная математика и  
информатика»

Научный руководитель:

Профессор кафедры статистического  
моделирования  
д. ф.-м. н. Н. Э. Голяндина

Рецензент:

Лектор, университет Кардиффа  
А. Н. Пепелышев

Санкт-Петербург

2025

Saint Petersburg State University  
Applied Mathematics and Computer Science

**POGREBNIKOV Nikolay Vadimovich**

**Graduation Project**

**MODIFICATIONS OF SINGULAR SPECTRUM ANALYSIS FOR TIME  
SERIES ANALYSIS**

Scientific Supervisor:  
Professor, Department of Statistical  
Modelling N. E. Golyandina

Reviewer:  
Lecturer, University of Cardiff  
A. N. Pepelyshev

Saint Petersburg  
2025

# Оглавление

<b>Введение</b>	6
<b>Глава 1. Метод Singular spectrum analysis (SSA)</b>	9
1.1. Алгоритм метода SSA	9
1.2. Свойства SSA	11
1.2.1. Ранг ряда	11
1.2.2. Точная разделимость	11
1.2.3. Асимптотическая разделимость	13
1.2.4. Частотная разделимость	13
1.2.5. Вложенные варианты SSA	15
1.2.6. SSA как линейный фильтр	16
1.3. Многомерные варианты SSA	18
1.3.1. MSSA	19
1.3.2. 2d-SSA	20
<b>Глава 2. Метод Generalized singular spectrum analysis (GSSA)</b>	21
2.1. Алгоритм метода GSSA	21
2.2. Свойства GSSA	23
2.2.1. Веса	23
2.2.2. Ранг ряда	23
2.2.3. GSSA как линейный фильтр	23
<b>Глава 3. Метод Circulant singular spectrum analysis (CiSSA)</b>	25
3.1. Алгоритм метода CiSSA	26
3.2. Свойства	30
3.2.1. Связь CiSSA с разложением Фурье	30
3.2.2. Точная разделимость	31
3.2.3. Асимптотическая разделимость	31
3.2.4. Выбор длины окна	32

3.3.	Обзор литературы . . . . .	33
3.3.1.	Cognitive Load Detection through EEG Lead-Wise Feature Optimization and Ensemble Classification . . . . .	33
3.3.2.	Application of visual stratigraphy from line-scan images to constrain chronology and melt features of a firn core from coastal Antarctica .	34
3.3.3.	Выводы . . . . .	34
<b>Глава 4.</b>	<b>Метод Functional singular spectrum analysis (FSSA) . . . . .</b>	<b>36</b>
4.1.	Алгоритм FSSA . . . . .	36
4.2.	Практическая реализация алгоритма FSSA . . . . .	39
4.3.	Разделимость . . . . .	41
<b>Глава 5.</b>	<b>Сравнения алгоритмов . . . . .</b>	<b>42</b>
5.1.	Сравнение SSA и GSSA . . . . .	42
5.1.1.	Линейные фильтры . . . . .	42
5.1.2.	Фильтры в различных точках . . . . .	44
5.1.3.	Отделение сигнала от шума . . . . .	45
5.1.4.	Вложенный вариант . . . . .	46
5.2.	Различия SSA, CiSSA и Фурье . . . . .	48
5.2.1.	Автоматическая группировка . . . . .	48
5.2.2.	Собственные пространства . . . . .	48
5.2.3.	Точная разделимость . . . . .	48
5.2.4.	Асимптотическая разделимость . . . . .	50
5.2.5.	Выделение тренда . . . . .	52
5.2.6.	Отделение сигнала от шума . . . . .	53
5.2.7.	Разделение трендовых составляющих между собой . . . . .	56
5.2.8.	Преимущества и недостатки методов SSA, Фурье и CiSSA . . . . .	56
5.2.9.	Проверка алгоритмов на реальных данных . . . . .	58
5.3.	Сравнение FSSA, MSSA, 2d-SSA . . . . .	62
5.3.1.	Численное сравнение . . . . .	62

<b>Заключение</b> . . . . .	64
<b>Список литературы</b> . . . . .	65

## Введение

Временные ряды представляют собой упорядоченную последовательность данных, собранных или измеренных в хронологическом порядке. Они играют ключевую роль в анализе и прогнозировании различных явлений в таких областях, как экономика, финансы, климатология и медицина. Понимание эволюции этих явлений во времени критично для выявления тенденций, циклов и аномалий.

Для уточнения терминологии, следует отметить, что *временной ряд длины  $N$*  представляет собой упорядоченную конечную последовательность значений, которая записывается как  $\mathbf{X} = (x_1, \dots, x_N)$ ,  $x_i \in \mathbb{R}$ . Одним из основных аспектов анализа временных рядов является разделение их на составляющие. Среди таких компонентов важными являются *тренд*, который отражает медленно изменяющуюся долгосрочную динамику ряда, и *сезонность*, представляющая собой периодические колебания, вызванные повторяющимися факторами, такими как климатические или экономические циклы.

Для эффективного анализа и понимания структуры временных рядов разработаны различные методы, позволяющие разделить ряд на его компоненты. Существует два вида разделимости: *точная разделимость*, которая характеризует способность метода точно выделять отдельные компоненты ряда, и *асимптотическая разделимость*, которая показывает, что ошибка разделения уменьшается с получением новых данных.

Теперь формально. Пусть временной ряд состоит из двух компонент:  $\mathbf{X}_N = \mathbf{X}_N^{(1)} + \mathbf{X}_N^{(2)}$ .  $M$  – метод разделения ряда на компоненты с параметрами  $\Theta$ .  $\hat{\mathbf{X}}_N^{(1)}$  – оценка  $\mathbf{X}_N^{(1)}$ .

**Определение 1.** Ряды  $\mathbf{X}_N^{(1)}$  и  $\mathbf{X}_N^{(2)}$  точно разделимы методом  $M$ , если существует такое  $\Theta$ , что  $\text{MSE}(\mathbf{X}_N^{(1)}, \hat{\mathbf{X}}_N^{(1)}) = 0$ .

**Определение 2.** Ряды  $\mathbf{X}_N^{(1)}$  и  $\mathbf{X}_N^{(2)}$  асимптотически разделимы методом  $M$ , если существует последовательность  $\Theta(N)$ ,  $N \rightarrow \infty$ , что  $\text{MSE}(\mathbf{X}_N^{(1)}, \hat{\mathbf{X}}_N^{(1)}) \rightarrow 0$ .

**Замечание 1.**  $\hat{\mathbf{X}}^{(2)} = \mathbf{X} - \hat{\mathbf{X}}^{(1)}$  является оценкой для  $\mathbf{X}^{(2)}$ , в условиях асимптотической разделимости выполнено  $\text{MSE}(\mathbf{X}^{(2)}, \hat{\mathbf{X}}^{(2)}) \rightarrow 0$ .

Методы разделения временных рядов играют ключевую роль в выделении тренда,

сезонности и других структурных компонент, что позволяет глубже понять и моделировать временные зависимости.

В данной работе будут рассмотрены следующие постановки задачи разделения временных рядов:

1. Разделение временного ряда на компоненты, соответствующие определенным частотным диапазонам;
2. Разделение временного ряда на компоненты без привязки к частотным характеристикам, то есть в их исходном виде.

Анализ сингулярного спектра (**SSA** [5]) — метод, целью которого является разложение исходного ряда на сумму небольшого числа интерпретируемых компонентов, таких как медленно изменяющаяся тенденция (тренд), колебательные компоненты (сезонность) и шум. Позволяет решать как задачу в формулировке 1, так и её обобщение, представленное в 2. При этом, базовый алгоритм метода **SSA** не требует стационарности ряда, знания модели тренда, а также сведений о наличии в ряде периодиках, а за счет своего адаптивного базиса позволяет подстраиваться под любой входной ряд.

В данном исследовании рассматриваются модификации **SSA**, предложенные другими авторами, а именно, **GSSA** [9] и **CiSSA** [1], **FSSA** [10].

**GSSA** отличается от базового **SSA** тем, что он добавляет веса на определенном этапе алгоритма **SSA**. В некоторых случаях это может оказаться полезным, в других — повлиять на разделимость в худшую сторону. Это исследование раскрывает смысловую ценность **GSSA** с точки зрения линейных фильтров и отмечает ситуации, где такой алгоритм предпочтительнее стандартного **SSA**.

В алгоритме **CiSSA** предложено решение задачи разделения временного ряда компонентам, отвечающим за заранее известные диапазоны частот (задача в постановке 1). За счет этого можно автоматически группировать компоненты по частотам, однако именно поэтому алгоритм лишается адаптивности, которая имеется в **SSA**.

**FSSA** рассматривается как многомерная модификация **SSA**, основанная на скрещивании подходов функционального анализа и теории **SSA**.

Целью работы является описание модификаций в контексте теории **SSA** и на этой основе сравнение методов по теоретическим свойствам и численно.

Далее кратко опишем структуру работы. В разделе 1 рассматриваются базовый метод **SSA**, его ключевые свойства и обобщения **MSSA** и **2d-SSA** на многомерный случай. В секциях 2, 5.1 показан алгоритм **GSSA** и проведено сравнение с **SSA**. В следующих разделах 3, 5.2 представлен метод **CiSSA**, также с описанием его основных характеристик и проведено сравнение с **SSA**. Затем в секциях 4, 5.3 рассматривается алгоритм **FSSA** и его сравнение с **2d-SSA** и **MSSA**. В заключительной секции 5.3.1 подведены основные итоги исследования.

В предыдущей научно-исследовательской работе было проведено сравнение алгоритмов **SSA** и **CiSSA** с точки зрения их способности к разделению временных рядов. Для этого была написана реализация алгоритма **CiSSA** на языке программирования R, проведено сравнение с методами **SSA** и преобразованием Фурье. Кроме того, была создана реализация алгоритма **GSSA** на языке R, и проведено сравнение его достоинств и недостатков с методом **SSA**.

В рамках текущего исследования было продолжено изучение указанных методов. Конкретнее, было рассмотрено влияние конкретной точки во времени на ошибку временного ряда для методов **GSSA** и **SSA**. Кроме того, список примеров для **CiSSA** был дополнен анализом сумм экспоненциально-модулированных гармоник. А также были изучены практические применения метода **CiSSA**. Наконец, было проведено численное сравнение методов **MSSA**, **2d-SSA** и **FSSA** с численной оценкой их эффективности.



## Глава 1

# Метод Singular spectrum analysis (SSA)

Рассмотрим базовый метод сингулярного спектрального анализа [5], его свойства, а также многомерные модификации MSSA и 2d-SSA.

### 1.1. Алгоритм метода SSA

Пусть  $N > 2$ , вещественнозначный временной ряд  $\mathbf{X} = (x_1, \dots, x_N)$  длины  $N$ . Базовый алгоритм SSA состоит из четырех шагов.

#### Вложение

Параметром этого шага является  $L$  — некоторое целое число (длина окна),  $1 < L < N$ . Строится  $L$ -траекторная матрица  $\mathbf{X}$ , состоящая из  $K = N - L + 1$  векторов вложения:

$$\mathcal{T}(\mathbf{X}) = \mathcal{T}_{SSA}(\mathbf{X}) = \mathbf{X} = \begin{pmatrix} x_1 & x_2 & x_3 & \dots & x_K \\ x_2 & x_3 & x_4 & \dots & x_{K+1} \\ x_3 & x_4 & x_5 & \dots & x_{K+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_L & x_{L+1} & x_{L+2} & \dots & x_N \end{pmatrix}. \quad (1.1)$$

Полезным свойством является то, что матрица  $\mathbf{X}$  имеет одинаковые элементы на антидиагоналях. Таким образом,  $L$ -траекторная матрица является ганкелевой.  $\mathcal{T}_{SSA}$  называется оператором вложения. Обозначим множество всех возможных траекторных матриц как  $\mathcal{M}_{L,K}^{(H)}$ . Буква  $H$  используется, чтобы подчеркнуть, что эти матрицы имеют ганкелеву структуру.

#### Сингулярное разложение (SVD)

Результатом этого шага является сингулярное разложение (**SVD**) траекторной матрицы ряда.

Пусть  $\mathbf{S} = \mathbf{X}\mathbf{X}^T$ ,  $\lambda_1, \dots, \lambda_L$  — собственные числа матрицы  $\mathbf{S}$ , взятые в неубывающем порядке, и  $U_1, \dots, U_L$  — ортонормированная система собственных векторов, соответствующих собственным числам матрицы  $\mathbf{S}$ .

Определим  $d = \max \{i : \lambda_i > 0\}$  и  $V_i = \mathbf{X}^T U_i / \sqrt{\lambda_i}$ . Тогда сингулярным разложением называется представление матрицы в виде:

$$\mathbf{X} = \mathbf{X}_1 + \dots + \mathbf{X}_d = \sum_{i=1}^d \sqrt{\lambda_i} U_i V_i^T. \quad (1.2)$$

Набор  $(\sqrt{\lambda_i}, U_i, V_i^T)$  называется  $i$ -й собственной тройкой разложения (1.2).

## Группировка

На основе разложения (1.2) производится процедура группировки, которая делит все множество индексов  $\{1, \dots, d\}$  на  $m$  непересекающихся подмножеств  $I_1, \dots, I_m$ . Это разбиение является параметром шага группировки.

Пусть  $I = \{i_1, \dots, i_p\}$ , тогда  $\mathbf{X}_I = \mathbf{X}_{i_1} + \dots + \mathbf{X}_{i_p}$ . Такие матрицы вычисляются для каждого  $I = I_1, \dots, I_m$ . В результате получаются матрицы  $\mathbf{X}_{I_1}, \dots, \mathbf{X}_{I_m}$ . Тем самым разложение (1.2) может быть записано в сгруппированном виде:

$$\mathbf{X} = \mathbf{X}_{I_1} + \dots + \mathbf{X}_{I_m}.$$

## Диагональное усреднение

Пусть  $\mathbf{Y}$  — матрица размерности  $L \times K$ .  $L^* = \min(L, K)$ ,  $K^* = \max(L, K)$ . Диагональное усреднение переводит матрицу  $\mathbf{Y}$  в временной ряд  $g_1, \dots, g_N$ :

$$g_k = \begin{cases} \frac{1}{k+1} \sum_{m=1}^{k+1} y_{m,k-m+2}^* & \text{для } 1 \leq k < L^*, \\ \frac{1}{L^*} \sum_{m=1}^{L^*} y_{m,k-m+2}^* & \text{для } L^* \leq k < K^* + 1, \\ \frac{1}{N-k} \sum_{m=k-K^*+2}^{N-K^*+1} y_{m,k-m+2}^* & \text{для } K^* + 1 \leq k \leq N. \end{cases}$$

После применения этой операции к матрицам  $\mathbf{X}_{I_1}, \dots, \mathbf{X}_{I_m}$ , получаются  $m$  новых рядов:  $\tilde{\mathbf{X}}_1, \dots, \tilde{\mathbf{X}}_m$ . Результатом данного шага и всего алгоритма является разложение временного ряда  $\mathbf{X} = \tilde{\mathbf{X}}_1 + \dots + \tilde{\mathbf{X}}_m$ .

То же самое можно переписать в операторном виде:

$$\tilde{X} = \mathcal{T}^{-1} \circ \Pi_H(\tilde{X}^{(k)}),$$

$\Pi_H$  – оператор проектирования на множество  $\mathcal{M}_{L,K}^{(H)}$ .

## 1.2. Свойства SSA

### 1.2.1. Ранг ряда

Зафиксируем ряд  $X = (x_1, \dots, x_N)$  длины  $N > 3$  и длину окна  $L$ .

Рассмотрим базовый SSA. В процессе процедуры вложения получаем последовательность векторов вложения:

$$X_i^{(L)} = X_i = (x_{i-1}, \dots, x_{i+L-2}), \quad i = 1, \dots, K,$$

$\mathcal{L}^{(L)} = \mathcal{L}^{(L)}(X) \stackrel{\text{def}}{=} \text{span}(X_1, \dots, X_K)$  — траекторное пространство ряда  $X$ . При этом, если  $\dim \mathcal{L}^{(L)} = \text{rank } X = d$ , то будем говорить, что ряд  $X$  имеет  $L$ -ранг  $d$  и записывать это как  $\text{rank}_L = d$ .

### 1.2.2. Точная разделимость

Ранее было дано более общее определение 1 точной разделимости. Рассмотрим его с другой стороны.

Пусть временной ряд  $X = X^{(1)} + X^{(2)}$  и задачей является нахождение этих слагаемых. В результате базового алгоритма SSA при  $m = 2$  также получаем 2 ряда. Возникает вопрос: в каких случаях мы можем так выбрать параметр алгоритма  $L$  и так сгруппировать собственные тройки, чтобы получить исходные ряды без смешиваний? При выборе длины окна  $L$  каждый из рядов  $X^{(1)}$ ,  $X^{(2)}$ ,  $X$  порождает траекторную матрицу  $X^{(1)}$ ,  $X^{(2)}$ ,  $X$ .

**Определение 3.** Будем говорить, что ряды  $X^{(1)}$  и  $X^{(2)}$  слабо  $L$ -разделимы, если пространства, порождаемые строками  $X^{(1)}$  и  $X^{(2)}$  ортогональны [5].

Если выполняется условие слабой  $L$ -разделимости, тогда существует такое сингулярное разложение траекторной матрицы  $\mathbf{X}$  ряда  $\mathbf{X}$ , что его можно разбить на две части, являющиеся сингулярными разложениями траекторных матриц рядов  $\mathbf{X}^{(1)}$  и  $\mathbf{X}^{(2)}$  [5].

**Определение 4.** Будем говорить, что ряды  $\mathbf{X}^{(1)}$  и  $\mathbf{X}^{(2)}$  сильно  $L$ -разделимы, если они слабо  $L$ -разделимы и после SVD множества сингулярных чисел траекторных матриц рядов не имеют совпадений [5].

Если выполняется условие сильной  $L$ -разделимости, тогда любое сингулярное разложение траекторной матрицы  $\mathbf{X}$  ряда  $\mathbf{X}$  можно разбить на две части, являющиеся сингулярными разложениями траекторных матриц рядов  $\mathbf{X}^{(1)}$  и  $\mathbf{X}^{(2)}$  [5]. Это будет означать, что для разложения ряда базовым методом SSA с  $m = 2$  и таким  $L$  будет выполняться  $\text{MSE}(\mathbf{X}^{(1)}, \hat{\mathbf{X}}^{(1)}) = 0$  (а значит и  $\text{MSE}(\mathbf{X}^{(2)}, \hat{\mathbf{X}}^{(2)}) = 0$ ).

Рассмотрим таблицу, в которой знаком  $+$  отмечены пары рядов, для которых существуют группировка и параметр  $L$ , при которых они разделимы (точно разделимы). Данная таблица 1.1 и условия разделимости с доказательствами взяты из книги [5].

Таблица 1.1. Точная разделимость

	const	cos	exp	exp cos	ak+b
const	-	+	-	-	-
cos	+	+	-	-	-
exp	-	-	-	+	-
exp cos	-	-	+	+	-
ak+b	-	-	-	-	-

Отметим, что  $+$  в таблице 1.1 для  $x_n^{(\cos_1)} = A_1 \cos(2\pi\omega_1 n + \varphi_1)$ ,  $x_n^{(\cos_2)} = A_2 \cos(2\pi\omega_2 n + \varphi_2)$  достигается, если  $L\omega_1 \in \mathbb{N}$ ,  $K\omega_1 \in \mathbb{N}$  или  $L\omega_2 \in \mathbb{N}$ ,  $K\omega_2 \in \mathbb{N}$ ,  $\omega_1 \neq \omega_2$  [5].

Однако, по таблице 1.1 видно, что условия точной разделимости достаточно жесткие и вряд ли выполнимы в реальных задачах. Тогда появляется такое понятие, как асимптотическая разделимость.

### 1.2.3. Асимптотическая разделимость

Для любого ряда  $\mathbf{X}$  длины  $N$  определим  $\mathbf{X}_{i,j} = (x_{i-1}, \dots, x_{j-1})$ ,  $1 \leq i \leq j < N$ . Пусть  $\mathbf{X}^{(1)} = (x_0^{(1)}, \dots, x_{N-1}^{(1)})$  и  $\mathbf{X}^{(2)} = (x_0^{(2)}, \dots, x_{N-1}^{(2)})$ . Тогда определим коэффициент корреляции следующим образом:

$$\rho_{i,j}^{(M)} = \frac{\left( \mathbf{X}_{i,i+M-1}^{(1)}, \mathbf{X}_{j,j+M-1}^{(2)} \right)}{\left\| \mathbf{X}_{i,i+M-1}^{(1)} \right\| \left\| \mathbf{X}_{j,j+M-1}^{(2)} \right\|}.$$

**Определение 5** ([5]). Ряды  $\mathbf{X}^{(1)}, \mathbf{X}^{(2)}$  называются  $\varepsilon$ -разделимыми при длине окна  $L$ , если

$$\rho^{(L,K)} \stackrel{\text{def}}{=} \max \left( \max_{1 \leq i,j \leq K} |\rho_{i,j}^{(L)}|, \max_{1 \leq i,j \leq L} |\rho_{i,j}^{(K)}| \right) < \varepsilon.$$

**Определение 6** ([5]). Если  $\rho^{(L(N),K(N))} \rightarrow 0$  при некоторой последовательности  $L = L(N)$ ,  $N \rightarrow \infty$ , то ряды  $\mathbf{X}^{(1)}, \mathbf{X}^{(2)}$  называются асимптотически  $L(N)$ -разделимыми.

Как можно заметить по таблице 1.2, для гораздо большего класса функций асимптотическая разделимость имеет место [5].

Таблица 1.2. Асимптотическая разделимость

	const	cos	exp	exp cos	ak+b
const	-	+	+	+	-
cos	+	+	+	+	+
exp	+	+	+	+	+
exp cos	+	+	+	+	+
ak+b	-	+	+	+	-

### 1.2.4. Частотная разделимость

Условия слабой разделимости и асимптотической можно переписать в другом виде, отталкиваясь от периодограммы.

Для начала введем определение разложения Фурье. Пусть  $\mathbf{X} = (x_1, \dots, x_N)$  — временной ряд

**Определение 7.** Разложение

$$x_n = c_0 + \sum_{k=1}^{\lfloor \frac{N+1}{2} \rfloor} (c_k \cos(2\pi nk/N) + s_k \sin(2\pi nk/N)), \quad (1.3)$$

где  $1 \leq n \leq N$  и  $s_{N/2} = 0$  для четного  $N$ , называется разложением Фурье ряда  $X$ .

Таким образом, можно выделить компоненту ряда, отвечающую за частоту  $w_k = \frac{k-1}{L}$ ,  $k = 1 : \lfloor \frac{N+1}{2} \rfloor$ .

Теперь, на основе (1.3) введем понятие периодограммы [5] как объекта, характеризующего вклад частот в разложение Фурье ряда.

**Определение 8.** Периодограммой ряда  $X = (x_1, \dots, x_N)$  будем называть функцию  $\Pi_f^N$ , которая задана на множестве частот  $\{k/N, k = 0, \dots, [N/2]\}$  формулой

$$\Pi_f^N(k/N) = \frac{N}{2} \begin{cases} 2c_0^2 & \text{для } k = 0, \\ c_k^2 + s_k^2 & \text{для } 0 < k < N/2, \\ 2c_{N/2}^2 & \text{для } k = N/2. \end{cases}$$

Последний случай имеет место только при четном  $N$ .

Фактически,  $\Pi_f^N(k/N)$  показывает мощность частоты  $\omega_k = \frac{k}{N}$ .

**Определение 9** ([5]).  $\Pi_f^N(k/N)$  называется мощностью частоты  $\omega_k = \frac{k}{N}$ . Набор частот  $\omega_k$  с положительными мощностями называется носителем периодограммы. Если носитель периодограммы принадлежит некоторому интервалу  $[a, b]$ , о этот интервал будем называть диапазоном частот периодограммы.

Теперь можно перейти к разделимости двух рядов с точки зрения периодограмм. Пусть  $X_N = X_N^{(1)} + X_N^{(2)}$  – временной ряд длины  $N$ ,  $L$  – длина окна,  $K = N - L + 1$ .

**Предложение 1** ([5]). Если носители периодограмм отрезков ряда  $X_N^{(1)}$  длины  $L$  не пересекаются с носителями периодограмм отрезков ряда  $X_N^{(2)}$  длины  $L$  и аналогичное утверждение справедливо для отрезков рядов длины  $K$ , то ряды  $X_N^{(1)}$  и  $X_N^{(2)}$  слабо разделимы.

Теперь можно перейти к аналогичному предложению для асимптотической разделимости. Но для начала определим меру спектральной ортогональности рядов  $X_N^{(1)}$  и  $X_N^{(2)}$ .

**Определение 10.** Величину

$$\rho_{12}^{(\Pi)} = \sum_{k=0}^{\lfloor \frac{N+1}{2} \rfloor} \frac{\sqrt{\Pi_{f_1}^N(k/N) \Pi_{f_2}^N(k/N)}}{\sqrt{\sum_{k=0}^{\lfloor N/2 \rfloor} \Pi_{f_1}^N(k/N)} \sqrt{\sum_{k=0}^{\lfloor N/2 \rfloor} \Pi_{f_2}^N(k/N)}} \quad (13)$$

будем называть *спектральным коэффициентом корреляции* рядов  $X_N^{(1)}$  и  $X_N^{(2)}$ .

**Предложение 2.** Если спектральные коэффициенты корреляции отрезков ряда  $X^{(1)}$  длины  $L = L(N)$  и отрезков ряда  $X^{(2)}$  длины  $L$  равномерно стремятся к нулю при  $N \rightarrow \infty$  и аналогичное утверждение справедливо для отрезков рядов длины  $K = K(N)$ , то ряды  $X^{(1)}$  и  $X^{(2)}$  асимптотически разделимы.

### 1.2.5. Вложенные варианты SSA

В алгоритме базового SSA используется SVD-разложение траекторной матрицы. Поскольку оно обладает наилучшими аппроксимационными свойствами среди методов разложения матриц на матрицы меньшего ранга, применение базового SSA обеспечивает наилучшее разделение сигнала и шума. Однако, как показывают условия точной и асимптотической разделимости, компоненты сигнала удаётся разделить лишь при достаточно строгих требованиях. Поэтому можно рассматривать различные альтернативные алгоритмы, способным разлагать сигнал на компоненты при менее жёстких условиях. Отсюда возникает идея вложенных вариантов SSA.

**Определение 11** ([6]). Пусть временной ряд состоит из двух компонент сигнала и шума:  $X = S + X_{\text{Noise}} = S^{(1)} + S^{(2)} + X_{\text{Noise}}$ .

**Вложенный вариант SSA** — двухэтапный метод:

1. Задается  $r$ .  $\tilde{S}$  — сумма первых  $r$  слагаемых SVD разложения траекторной матрицы сигнала  $S$  с помощью базового SSA.
2. Применение другого метода к  $\tilde{S}$  для улучшения разделимости:  $\tilde{S} = \tilde{S}_1 + \tilde{S}_2$ .

Таким образом, получается наилучшим образом разделить как сигнал от шума, так и компоненты сигнала между собой.

В данной работе будут использоваться вложенные варианты SSA EOSSA и SSA FOSSA. Подробнее про них можно почитать в [3]. Кроме того, благодаря ним можно автоматически группировать компоненты в соответствии с заранее заданными частотами.

### 1.2.6. SSA как линейный фильтр

Разложение временного ряда методом SSA можно интерпретировать как применение линейных фильтров. Для дальнейшего исследования введем следующие определения.

**Определение 12.** Рассмотрим бесконечный временной ряд  $X = (\dots, x_{-1}, x_0, x_1, \dots)$ . Линейный конечный фильтр — это оператор  $\Phi$ , который преобразует временной ряд  $X$  в новый по следующему правилу:

$$y_j = \sum_{i=-r_1}^{r_2} h_i x_{j-i}; \quad r_1, r_2 < \infty.$$

Набор коэффициентов  $h_i$  — импульсная характеристика фильтра.

Там, где не оговорено обратного, будем называть линейный конечный фильтр просто линейным фильтром.

**Определение 13.** Передаточная функция линейного фильтра  $\Phi$ :

$$H_\Phi(z) = \sum_{i=-r_1}^{r_2} h_i z^{-i}.$$

**Определение 14.** Амплитудно-частотная характеристика (АЧХ) линейного фильтра  $\Phi$ :

$$A_\Phi(\omega) = |H_\Phi(e^{i2\pi\omega})|.$$

АЧХ фильтра — это график или функция, которая показывает, как фильтр изменяет амплитуды (силу) разных частот входного сигнала.

**Определение 15.** Фазово-частотная характеристика (ФЧХ) линейного фильтра  $\Phi$ :

$$\phi_\Phi(\omega) = \text{Arg}(H_\Phi(e^{i2\pi\omega})).$$



Посмотрим, как это выглядит для косинуса. Пусть исходный ряд  $x_n^{\cos} = \cos 2\pi\omega n$ . Тогда:

$$y_j = A_\Phi(\omega) \cos(2\pi\omega j + \phi_\Phi(\omega))$$

Теперь рассмотрим алгоритм **SSA** с точки зрения линейных фильтров [7]. Пусть  $\mathbf{X} = (x_1, \dots, x_N)$  — временной ряд длины  $N$ ,  $K = N - L + 1$ ,  $L^* = \min(L, K)$ . Пусть  $L$  будет длиной окна, а  $(\sqrt{\lambda}, U, V)$  — одной из собственных троек. Определим диагональную матрицу  $N \times N$ :

$$\mathbf{D} = \text{diag}(1, 2, 3, \dots, L^* - 1, L^*, L^*, \dots, L^*, L^* - 1, \dots, 2, 1)$$

и матрицу  $K \times N$

$$\mathbf{W} = \begin{pmatrix} u_1 & u_2 & u_3 & \cdots & u_L & 0 & \cdots & 0 & 0 & 0 \\ 0 & u_1 & u_2 & u_3 & \cdots & u_L & 0 & \cdots & 0 & 0 \\ \vdots & 0 & \ddots & \ddots & \ddots & \cdots & \ddots & 0 & \cdots & 0 \\ 0 & \cdots & 0 & u_1 & u_2 & u_3 & \cdots & u_L & 0 & \vdots \\ 0 & 0 & \cdots & 0 & u_1 & u_2 & u_3 & \cdots & u_L & 0 \\ 0 & 0 & 0 & \cdots & 0 & u_1 & u_2 & u_3 & \cdots & u_L \end{pmatrix}.$$

Здесь  $U = (u_1, \dots, u_L)$  — собственный вектор матрицы  $\mathbf{S}$ .

**Теорема 1.** Компонента временного ряда  $\tilde{\mathbf{X}}$ , восстановленная с использованием собственной тройки  $(\sqrt{\lambda}, U, V)$ , имеет вид:

$$\tilde{\mathbf{X}}^T = \mathbf{D}^{-1} \mathbf{W}^T \mathbf{W} \mathbf{X}^T.$$

*Доказательство.* Доказательство можно найти в [7] (неплохо бы расписать).  $\square$

Таким образом, для восстановления методом **SSA** средних точек (индексы от  $L$  до  $K$ ) имеем следующий фильтр:

$$\tilde{x}_s = \sum_{j=-(L-1)}^{L-1} \left( \sum_{k=1}^{L-|j|} u_k u_{k+|j|} / L \right) x_{s-j}, \quad L \leq s \leq K. \quad (1.4)$$

Похожим образом можно переписать **SSA** через линейные фильтры для точек в начале и конце.

### 1.3. Многомерные варианты SSA

Временные ряды могут быть не только одномерными, но и многомерными, то есть представлять собой наборы связанных наблюдений. В данной работе рассматриваются две модификации базового SSA: MSSA и 2d-SSA.

Обе эти модификации имеют схожую структуру с одномерным SSA, только нужно переопределить оператор вложения  $\mathcal{T}$  и понять, какую структуру будет иметь множество траекторных матриц  $\mathcal{M}_{L,K}^{(H)}$ .

Таким образом, имеем общую схему алгоритмов SSA:

#### 1. Вложение:

Для временного ряда  $\mathbf{X}$  строится траекторная матрица:

$$\mathbf{X} = \mathcal{T}(\mathbf{X})$$

#### 2. Разложение:

Траекторная матрица  $\mathbf{X}$  разлагается в сумму матриц ранга один:

$$\mathbf{X} = \sum_{j=1}^d \mathbf{X}_j$$

#### 3. Группировка:

Элементарные матрицы  $\mathbf{X}_j$  разбиваются на группы:

$$\mathbf{X} = \mathbf{X}_{I_1} + \dots + \mathbf{X}_{I_m}, \quad \text{где } \mathbf{X}_{I_k} = \sum_{j \in I_k} \mathbf{X}_j$$

#### 4. Реконструкция:

К сгруппированным матрицам применяется диагональное усреднение:

$$\tilde{\mathbf{X}} = \tilde{\mathbf{X}}_1 + \dots + \tilde{\mathbf{X}}_m, \quad \tilde{\mathbf{X}}_k = \mathcal{T}^{-1} \circ \Pi_H(\mathbf{X}_{I_k})$$

### 1.3.1. MSSA

Рассмотрим многомерный временной ряд, то есть набор  $\{\mathbf{X}^{(p)} = (x_j^{(p)})_{j=1}^{N_p}, p = 1, \dots, s\}$  из  $s$  временных рядов длины  $N_p$ , где  $p = 1, \dots, s$ .

Обозначим  $\mathbf{X} = (\mathbf{X}^{(1)}, \dots, \mathbf{X}^{(s)})$  как исходные данные для алгоритма MSSA [4]. Пусть  $L$  — длина окна,  $1 < L < \min(N_p, p = 1, \dots, s)$ . Для каждого временного ряда  $\mathbf{X}^{(p)}$  формируем  $K_p = N_p - L + 1$  векторов  $\mathbf{X}_j^{(p)} = (x_j^{(p)}, \dots, x_{j+L-1}^{(p)})^T$ , где  $1 \leq j \leq K_p$ . Обозначим  $K = \sum_{p=1}^s K_p$ . Траекторная матрица многомерного ряда  $\mathbf{X}$  — это матрица размера  $L \times K$  следующего вида:

$$\mathcal{T}_{\text{MSSA}}(\mathbf{X}) = \mathbf{X} = [\mathbf{X}_1^{(1)} : \dots : \mathbf{X}_{K_1}^{(1)} : \dots : \mathbf{X}_1^{(s)} : \dots : \mathbf{X}_{K_s}^{(s)}] = [\mathbf{X}^{(1)} : \dots : \mathbf{X}^{(s)}],$$

$\mathbf{X}^{(p)} = \mathcal{T}_{\text{SSA}}(\mathbf{X}^{(p)})$  — траекторная матрица одномерного ряда  $\mathbf{X}^{(p)}$ . Таким образом, траекторная матрица системы временных рядов имеет блочно-ганкелеву структуру. Заметим, что

$$\mathcal{T}_{\text{MSSA}}^{-1}(\mathbf{X}) = [\mathcal{T}_{\text{SSA}}^{-1}(\mathbf{X}^{(1)}) : \dots : \mathcal{T}_{\text{SSA}}^{-1}(\mathbf{X}^{(s)})].$$

### Комментарии

Собственные векторы  $U_i$  из SVD траекторной матрицы  $\mathbf{X} = \sum_i \sqrt{\lambda_i} U_i V_i^T$  формируют общее базисное пространство для всех временных рядов. Векторы  $V_i$  содержат подкомпоненты  $V_i^{(p)}$ , соответствующие каждому ряду:

$$V_i = \begin{pmatrix} V_i^{(1)} \\ \vdots \\ V_i^{(s)} \end{pmatrix},$$

$V_i^{(p)} \in \mathbb{R}^{K_p}$  принадлежит строковому пространству  $p$ -го ряда.  $U_i$  отражают общую структуру,  $V_i^{(p)}$  — её проявление в отдельных рядах.

Кроме того, преимущество MSSA проявляется, когда ряды имеют общую с точки зрения SSA структуру.

### 1.3.2. 2d-SSA

2d-SSA – это расширение базового SSA для двумерных массивов [4] (например, изображений). Данные представляются в виде матрицы:

$$\mathbf{X} = (x_{ij})_{i,j=1}^{N_x, N_y}, \quad \text{где } N_x \times N_y \text{ — размер массива.}$$

Матрица содержит наблюдения, упорядоченные по двум пространственным или иным измерениям (например, изображение).

Параметрами метода являются размеры окна  $(L_x, L_y)$ , где  $1 \leq L_x \leq N_x$ ,  $1 \leq L_y \leq N_y$ .

Определим  $\mathcal{T}$ :

1. Из массива  $\mathbf{X}$  выделяются все возможные подматрицы размера  $L_x \times L_y$  с помощью скользящего окна.
2. Каждая подматрица  $\mathbf{X}_{k,l}^{(L_x, L_y)}$  преобразуется в столбец:  $\mathbf{X}_{k+(l-1)K_x} = \text{vec}(\mathbf{X}_{k,l}^{(L_x, L_y)})$ .
3. Траекторная матрица строится как объединение этих столбцов:

$$\mathcal{T}_{2D-SSA}(\mathbf{X}) = \mathbf{X} = [\mathbf{X}_1 : \dots : \mathbf{X}_{K_x K_y}].$$

Матрица  $\mathbf{X}$  имеет блочно-ганкелеву структуру:

$$\mathbf{X} = \begin{pmatrix} \mathbf{H}_1 & \mathbf{H}_2 & \dots & \mathbf{H}_{K_y} \\ \mathbf{H}_2 & \mathbf{H}_3 & \dots & \mathbf{H}_{K_y+1} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{H}_{L_y} & \mathbf{H}_{L_y+1} & \dots & \mathbf{H}_{N_y} \end{pmatrix},$$

где каждая  $\mathbf{H}_j$  — ганкелевская матрица, построенная из столбцов  $\mathbf{X}$ .

### Комментарии

Связь с MSSA: если  $L_x = 1$  или  $L_y = 1$ , 2d-SSA эквивалентен MSSA для временных рядов одинаковой длины. Поэтому его можно назвать обобщением MSSA.

Также при применении 2d-SSA важен порядок следования строк и столбцов в  $\mathbf{X}$ , иными словами, предполагается регулярное поведение, как по строкам, так и по столбцам. В отличие от MSSA, где регулярное поведение нужно только по времени.

## Глава 2

## Метод Generalized singular spectrum analysis (GSSA)

В этом разделе описана модификация **SSA** на основе добавления специальных весов к строкам  $L$ -траекторной матрицы  $\mathbf{X}$  [9]. Это делается для уменьшения растекания частоты (spectral leakage). Авторы метода называют его обобщенным, поскольку базовый **SSA** является частным случаем **GSSA** с параметром  $\alpha = 0$ .

## 2.1. Алгоритм метода GSSA

Алгоритм **GSSA** сильно схож с базовым **SSA**. Пусть  $N > 2$ , вещественнозначный временной ряд  $\mathbf{X} = (x_1, \dots, x_N)$  длины  $N$ . Фиксируется параметр  $\alpha \geq 0$ , отвечающий за веса:

$$\mathbf{w}^{(\alpha)} = (w_1, w_2, \dots, w_L) = \left( \left| \sin \left( \frac{\pi n}{L+1} \right) \right| \right)^\alpha, \quad \text{для } n = 1, 2, \dots, L.$$




Рис. 2.1. График весов для различных значений  $\alpha$

### Вложение

$L$  — некоторое целое число (длина окна),  $1 < L < N$ . Строится  $L$ -траекторная матрица  $\mathbf{X}^{(\alpha)}$ :

$$\mathbf{X}^{(\alpha)} = \begin{pmatrix} w_1 x_1 & w_1 x_2 & w_1 x_3 & \dots & w_1 x_K \\ w_2 x_2 & w_2 x_3 & w_2 x_4 & \dots & w_2 x_{K+1} \\ w_3 x_3 & w_3 x_4 & w_3 x_5 & \dots & w_3 x_{K+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_L x_L & w_L x_{L+1} & w_L x_{L+2} & \dots & w_L x_N \end{pmatrix}. \quad (2.1)$$

### Сингулярное разложение (SVD)

Этот шаг такой же, как и в SSA, только матрица  $\mathbf{X}$  заменяется на  $\mathbf{X}^{(\alpha)}$ . Будем обозначать собственные тройки в этом случае так:  $(\sqrt{\lambda^{(\alpha)}}, U^{(\alpha)}, V^{(\alpha)})$ .

### Группировка

В точности как в SSA. Тем самым, разложение может быть записано в сгруппированном виде:

$$\mathbf{X}^{(\alpha)} = \mathbf{X}_{I_1}^{(\alpha)} + \dots + \mathbf{X}_{I_m}^{(\alpha)}.$$

### Взвешенное диагональное усреднение

Поскольку траекторная матрица была изменена весами, то диагональное усреднение тоже будет зависеть от весов.

Пусть  $\mathbf{Y}$  — матрица размерности  $L \times K$ . Взвешенное диагональное усреднение переводит матрицу  $\mathbf{Y}$  в временной ряд  $g_1, \dots, g_N$ :

$$g_k = \begin{cases} \frac{1}{\sum_{n=1}^k w_n} \sum_{m=1}^{k+1} y_{m,k-m+2}^* & \text{для } 1 \leq k < L, \\ \frac{1}{\sum_{n=1}^L w_n} \sum_{m=1}^L y_{m,k-m+2}^* & \text{для } L \leq k < K+1, \\ \frac{1}{\sum_{n=k-K+1}^L w_n} \sum_{m=k-K+2}^{N-K+1} y_{m,k-m+2}^* & \text{для } K+1 \leq k \leq N. \end{cases}$$

Применяя данную операцию к матрицам  $\mathbf{X}_{I_1}^{(\alpha)}, \dots, \mathbf{X}_{I_m}^{(\alpha)}$ , получаются  $m$  новых рядов:

$\mathbf{X}_1^{(\alpha)}, \dots, \mathbf{X}_m^{(\alpha)}$ . Результатом данного шага и всего алгоритма является разложение временного ряда  $\mathbf{X}_1^{(\alpha)} + \dots + \mathbf{X}_m^{(\alpha)} = \mathbf{X}^{(\alpha)}$ .

## 2.2. Свойства GSSA

### 2.2.1. Веса

Для минимизации эффекта спектрального размывания (spectral leakage), связанного с конечностью временного интервала наблюдений, к исходному ряду применялось оконное преобразование (tapering [12]). В качестве оконной функции используются степенные синус-косинусные веса (power-of-sine/cosine window).

Данное преобразование выполняет две ключевые функции:

1. Снижение краевых эффектов: умножение исходного ряда на убывающую к краям функцию  $w(t)$ ;
2. Сглаживание периодограммы: веса используются для усреднения значений.

Такой подход позволяет более точно отделять компоненты ряда друг от друга.

### 2.2.2. Ранг ряда

Зафиксируем ряд  $\mathbf{X} = (x_1, \dots, x_N)$  длины  $N > 3$  и длину окна  $L$ .

В секции 1.2.1 было введено понятие ранга ряда для базового SSA. Теперь рассмотрим GSSA и поймем, что для того же ряда  $\text{rank } \mathbf{X}^{(\alpha)} = \text{rank } \mathbf{X}$ , а значит, что для GSSA также применимы понятия  $L$ -ранга ряда. Из вида (2.1)  $\mathbf{X}^{(\alpha)}$  можно получить, что  $\mathbf{X}^{(\alpha)} = \text{diag}(w_1, w_2, \dots, w_L) \mathbf{X} = \text{diag}(\mathbf{w}^{(a)}) \mathbf{X}$ . Поскольку матрица  $\text{diag}(\mathbf{w}^{(a)})$  имеет ранг равный  $L$ , она диагональна, то и  $\text{rank } \mathbf{X}^{(\alpha)} = \text{rank } \text{diag}(\mathbf{w}^{(a)}) \mathbf{X} = \text{rank } \mathbf{X}$ .

### 2.2.3. GSSA как линейный фильтр

Аналогично SSA, метод GSSA можно переписать с помощью линейных фильтров. Пусть  $\mathbf{X} = (x_1, \dots, x_N)$  — временной ряд длины  $N$ ,  $K = N - L + 1$ ,  $L^* = \min(L, K)$ .  $(\sqrt{\lambda^{(\alpha)}}, U^{(\alpha)}, V^{(\alpha)})$  — одна из собственных троек. Определим диагональную матрицу  $N \times$

$N$ :

$$\mathbf{D}^{(\alpha)} = \text{diag}(w_1, w_1 + w_2, \dots, \sum_{i=1}^{L^*-1} w_i, \sum_{i=1}^{L^*} w_i, \sum_{i=1}^{L^*} w_i, \dots, \sum_{i=1}^{L^*} w_i, \sum_{i=2}^{L^*} w_i, \dots, w_{L^*-1} + w_{L^*}, w_{L^*})$$

и две матрицы  $K \times N$ :

$$\mathbf{W}^{(\alpha)} = \begin{pmatrix} u_1^{(\alpha)} & u_2^{(\alpha)} & u_3^{(\alpha)} & \dots & u_L^{(\alpha)} & 0 & \dots & 0 & 0 & 0 \\ 0 & u_1^{(\alpha)} & u_2^{(\alpha)} & u_3^{(\alpha)} & \dots & u_L^{(\alpha)} & 0 & \dots & 0 & 0 \\ \vdots & 0 & \ddots & \ddots & \ddots & \dots & \ddots & 0 & \dots & 0 \\ 0 & \dots & 0 & u_1^{(\alpha)} & u_2^{(\alpha)} & u_3^{(\alpha)} & \dots & u_L^{(\alpha)} & 0 & \vdots \\ 0 & 0 & \dots & 0 & u_1^{(\alpha)} & u_2^{(\alpha)} & u_3^{(\alpha)} & \dots & u_L^{(\alpha)} & 0 \\ 0 & 0 & 0 & \dots & 0 & u_1^{(\alpha)} & u_2^{(\alpha)} & u_3^{(\alpha)} & \dots & u_L^{(\alpha)} \end{pmatrix},$$

$$\mathbf{W}_w^{(\alpha)} = \begin{pmatrix} w_1 u_1^{(\alpha)} & w_2 u_2^{(\alpha)} & w_3 u_3^{(\alpha)} & \dots & w_L u_L^{(\alpha)} & 0 & \dots & 0 & 0 & 0 \\ 0 & w_1 u_1^{(\alpha)} & w_2 u_2^{(\alpha)} & w_3 u_3^{(\alpha)} & \dots & w_L u_L^{(\alpha)} & 0 & \dots & 0 & 0 \\ \vdots & 0 & \ddots & \ddots & \ddots & \dots & \ddots & 0 & \dots & 0 \\ 0 & \dots & 0 & w_1 u_1^{(\alpha)} & w_2 u_2^{(\alpha)} & w_3 u_3^{(\alpha)} & \dots & w_L u_L^{(\alpha)} & 0 & \vdots \\ 0 & 0 & \dots & 0 & w_1 u_1^{(\alpha)} & w_2 u_2^{(\alpha)} & w_3 u_3^{(\alpha)} & \dots & w_L u_L^{(\alpha)} & 0 \\ 0 & 0 & 0 & \dots & 0 & w_1 u_1^{(\alpha)} & w_2 u_2^{(\alpha)} & w_3 u_3^{(\alpha)} & \dots & w_L u_L^{(\alpha)} \end{pmatrix}.$$

Здесь  $U = (u_1, \dots, u_L)$  — собственный вектор матрицы  $\mathbf{S}$ .

**Теорема 2.** Компонента временного ряда  $\tilde{\mathbf{X}}$ , восстановленная с использованием собственной тройки  $(\sqrt{\lambda^{(\alpha)}}, U^{(\alpha)}, V^{(\alpha)})$ , имеет вид:

$$\tilde{\mathbf{X}}^T = \mathbf{D}^{(\alpha)-1} \mathbf{W}^{(\alpha)T} \mathbf{W}_w^{(\alpha)} \mathbf{X}^T.$$

*Доказательство.* Доказательство проводится аналогично доказательству теоремы 1.

□

Таким образом, для восстановления методом **GSSA** средних точек (индексы от  $L$  до  $K$ ) имеем следующий фильтр:

$$\tilde{x}_s = \sum_{j=-(L-1)}^{L-1} \left( \sum_{k=1}^{L-|j|} u_k^{(\alpha)} u_{k+|j|}^{(\alpha)} w_k / \sum_{i=1}^L w_i \right) x_{s-j}, \quad L \leq s \leq K. \quad (2.2)$$

Похожим образом можно переписать **GSSA** через линейные фильтры для точек в начале и конце.



## Глава 3

## Метод Circulant singular spectrum analysis (CiSSA)

В этом разделе описана модификация SSA на основе циркулярной матрицы [1]. В отличие от базового SSA, в CiSSA для каждого конкретного  $L$  базис разложения остается одинаковым для любого входного временного ряда. Поскольку из-за этого повышается интерпретируемость каждой компоненты в разложении, авторы метода назвали CiSSA автоматизированной версией SSA в том смысле, что компоненты ряда группируются по частотам самим алгоритмом. Сначала будет рассмотрен метод только для стационарного случая, затем показана применимость модифицированной версии CiSSA при использовании нестационарного ряда.

Стационарность подразумевает неизменность определенных свойств ряда во времени. Определим это понятие формально [5].

**Определение 16.** Пусть  $X = (x_1, \dots, x_n, \dots)$  — временной ряд. Ряд  $X$  называется стационарным, если существует функция  $R_X(k)$  ( $-\infty < k < +\infty$ ) такая, что для любых  $k, l \geq 1$

$$R_X^{(N)}(k, l) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{m=1}^N x_{k+m} x_{l+m} \xrightarrow{N \rightarrow \infty} R_X(k - l). \quad (3.1)$$

Если (3.1) выполняется, тогда  $R_X$  называется ковариационной функцией стационарного ряда  $X$ .

**Теорема 3.** Пусть  $R_X$  — ковариационная функция стационарного ряда  $X$ . Тогда существует конечная мера  $m_X$ , определенная на борелевских подмножествах  $(-1/2, 1/2]$ , такая, что

$$R_X(k) = \int_{(-\frac{1}{2}, \frac{1}{2}]} e^{i2\pi k\omega} m_X(d\omega).$$

Мера  $m_X$  называется спектральной мерой ряда  $X$ .

*Доказательство.* Доказательство в [5]. □

### 3.1. Алгоритм метода CiSSA

Данный алгоритм, как и SSA, состоит из четырех основных шагов.

Зафиксируем стационарный временной ряд  $\mathbf{X}$  состоящий из  $N$  элементов и выберем длину окна  $L$ .

#### Вложение

Такой же, как и в SSA. Считаем матрицу  $\mathbf{X}$ , заданную в (1.1).

#### Разложение

Для каждого  $k = 1 : L$  вычисляются собственные векторы  $U_k$ :

$$U_k = L^{-1/2}(u_{k,1} \cdot \dots, u_{k,L}), \text{ где } u_{k,j} = \exp\left(-i2\pi(j-1)\frac{k-1}{L}\right),$$

причем  $U_k = U_{L+2-k}^*$ ,  $U^*$  — комплексное сопряжение вектора  $U$ .

#### Элементарное разложение

Для каждой частоты  $\omega_k = \frac{k-1}{L}$ ,  $k = 1 : \lfloor \frac{L+1}{2} \rfloor$ , есть два собственных вектора:  $U_k$  и  $U_{L+2-k}$ . За частоту  $\omega_0$  отвечает один собственный вектор —  $U_0$ . Если же  $L$  — четное, то частоте  $\omega_{\frac{L}{2}+1}$  будет соответствовать один вектор  $U_{\frac{L}{2}+1}$ .

Следовательно, индексы группируются следующим образом:

$$B_1 = \{1\}; B_k = \{k, L+2-k\}, \text{ для } k = 1 : \lfloor \frac{L+1}{2} \rfloor; B_{\frac{L}{2}+1} = \left\{ \frac{L}{2} + 1 \right\}, \text{ если } L \bmod 2 = 0.$$

Таким образом, получается элементарная группировка по частотам  $\omega_k$ :

$$\mathbf{X}_{B_k} = \mathbf{X}_k + \mathbf{X}_{L+2-k} = U_k U_k^H \mathbf{X} + U_{L+2-k} U_{L+2-k}^H \mathbf{X}, \text{ для } k = 1 : \lfloor \frac{L+1}{2} \rfloor;$$

$$\mathbf{X}_{B_{\frac{L}{2}+1}} = \mathbf{X}_{\frac{L}{2}+1} = U_{\frac{L}{2}+1} U_{\frac{L}{2}+1}^H \mathbf{X}, \text{ если } L \bmod 2 = 0,$$

где  $U^H$  — это комплексное сопряжение и транспонирование вектора  $U$ .

Пусть  $d = \lfloor \frac{L+1}{2} \rfloor$ , если  $L \bmod 2 \neq 0$ , иначе  $d = \frac{L}{2} + 1$ . Тогда результатом данного шага будет разложение исходной матрицы  $\mathbf{X}$  в сумму матриц  $\mathbf{X}_{B_k}$ , отвечающих периодам с определенными частотами  $\omega_k$ :

$$\mathbf{X} = \sum_{k=1}^d \mathbf{X}_{B_k}.$$

## Группировка

Такой же шаг, как и в базовом SSA. Однако группировка будет производиться на непересекающиеся подгруппы по частотам от  $\omega_k$ , которые находятся в диапазоне от 0 до 0.5. То есть, заранее заданному произвольному количеству непересекающихся диапазонов  $I_i = [\omega_{i0}, \omega_{i1}]$ ,  $\omega_{i0} \leq \omega_{i1}$  и  $0 \leq \omega_{i0}, \omega_{i1} \leq 0.5$ , строятся матрицы  $\mathbf{X}_{I_i}$ , в которые входят суммы  $\mathbf{X}_{B_k}$ , отвечающие частотам  $\omega_k : \omega_{i0} \leq \omega_k \leq \omega_{i1}$ .

## Диагональное усреднение

Такой же шаг, как и в базовом SSA.

**Замечание 2.**  $U_k$  можно получить по аналогии с SSA.

Определим автоковариации:

$$\hat{\gamma}_m = \frac{1}{N-m} \sum_{t=1}^{N-m} x_t x_{t+m}, \quad m = 0 : (L-1).$$

На основе  $\hat{\gamma}_m$  определим матрицу:

$$\hat{\gamma}_L = \begin{pmatrix} \hat{\gamma}_0 & \hat{\gamma}_1 & \dots & \hat{\gamma}_{L-1} \\ \hat{\gamma}_1 & \hat{\gamma}_2 & \dots & \hat{\gamma}_{L-2} \\ \vdots & \vdots & \vdots & \vdots \\ \hat{\gamma}_{L-1} & \hat{\gamma}_{L-2} & \dots & \hat{\gamma}_0 \end{pmatrix}. \quad (3.2)$$

Данная матрица  $L \times L$  называется Теплицевой и используется в методе Toeplitz SSA (подробнее про данный метод можно прочитать в книге [5]). На ее основе составим циркулярную матрицу для алгоритма Circulant SSA [1]:

$$\hat{\mathbf{C}}_L = \begin{pmatrix} \hat{c}_0 & \hat{c}_1 & \dots & \hat{c}_{L-1} \\ \hat{c}_1 & \hat{c}_0 & \dots & \hat{c}_{L-2} \\ \vdots & \vdots & \vdots & \vdots \\ \hat{c}_{L-1} & \hat{c}_{L-2} & \dots & \hat{c}_0 \end{pmatrix}, \quad (3.3)$$

где  $\hat{c}_m = \frac{L-m}{L} \hat{\gamma}_m + \frac{m}{L} \hat{\gamma}_{L-m}$ ,  $m = 0 : L-1$ . Собственные числа матрицы  $\hat{\mathbf{C}}_L$ , определенной в (3.3), задаются по формуле:

$$\lambda_{L,k} = \sum_{m=0}^{L-1} \hat{c}_m \exp \left( i 2 \pi m \frac{k-1}{L} \right), \quad k = 1 : L, \text{ причем } \lambda_{L,k} = \lambda_{L,L+2-k},$$

а собственные вектора, связанные с  $\lambda_{L,k}$  — это векторы  $U_k$ .

**Замечание 3.**  $U_k U_k^H + U_{L+2-k} U_{L+2-k}^H$  является оператором проектирования на подпространство, которое порождено синусами и косинусами с частотой  $w_k = \frac{k-1}{L}$ .

**Замечание 4.** В разделе 3.2.1 рассмотрена связь между матрицей  $\mathbf{X}_{B_k}$  и разложениями Фурье для векторов вложения.

### Нестационарный случай

Для применения данного алгоритма на нестационарных временных рядах, авторами предлагается применить процедуру расширения ряда. Как утверждает авторами статьи [1], после расширения, CiSSA можно применить к нестационарному ряду. Сама процедура расширения ряда  $\mathbf{X}$  производится с использованием авторегрессионной (AR) модели. Эта процедура позволяет предсказать значения временного ряда за его пределами (экстраполяция) как в правом, так и в левом направлениях на заданное число шагов  $H$ . Таким образом, трендовая (нелинейная) компонента ряда будет выделяться заметно лучше. В ходе работы алгоритм выполняет следующие шаги:

1. **Построение дифференцированного ряда:** Временной ряд  $\mathbf{X}$  сначала преобразуется в дифференцированный ряд  $d\mathbf{X}$ , чтобы удалить трендовые компоненты;
2. **Определение порядка AR-модели:** Метод определяет порядок  $p$  AR-модели как целую часть от деления длины ряда  $N$  на 3. Это значение порядка модели  $p$  будет использовано для построения авторегрессионной модели на дифференцированном временном ряде;
3. **Построение AR-модели:** После этого для дифференцированного ряда вычисляются коэффициенты авторегрессионной модели  $A$  с использованием метода Юла-Уокера, основываясь на определенном ранее порядке  $p$ ;
4. **Правое расширение ряда:** С помощью AR-модели ряд  $d\mathbf{X}$  прогнозируется на  $H$  шагов вправо. Затем возвращается к своему изначальному состоянию путем интегрирования  $d\mathbf{X}$ . Получается расширение исходного ряда  $\mathbf{X}$  на  $H$  шагов вправо;

5. **Левое расширение ряда:** Аналогично предыдущему пункту, ряд прогнозируется на  $H$  шагов влево;
6. **Возвращение расширенного ряда:** В конце метод возвращает расширенный временной ряд  $X_{\text{extended}}$ , который содержит как левое, так и правое расширение на  $H$  шагов от исходного ряда  $X$ .

Таким образом, алгоритм расширения ряда позволяет выполнять предсказания временного ряда по обе стороны от его границ, основываясь на авторегрессионной модели, построенной на дифференцированном ряде, что полезно для выделения тренда.



Рис. 3.1. Расширение временного ряда IP values. Красным показан настоящий ряд, черным — его расширение

Однако поскольку мы рассматриваем расширенный ряд, то и периодические компоненты будут строиться по нему. Поэтому в угоду лучшего выделения трендовой составляющей, будет несколько жертвоваться точность разделения периодических компонентов.




Рис. 3.2. Расширение временного ряда синуса. Красным показан настоящий ряд, черным — его расширение

На рисунке 3.2 видно, что синус расширился неправильно, от концов настоящего ряда до концов расширенного значения постепенно уменьшались. Как будет показано в секции 5.2, это повлияет на значения ошибки выделения сигнала и его компонент.

## 3.2. Свойства

### 3.2.1. Связь CiSSA с разложением Фурье

Для описания конечных, но достаточно длинных рядов можно использовать разложение Фурье. Определение разложения Фурье было дано в (1.3).

Алгоритм CiSSA тесно связан с разложением Фурье. По замечанию 3 видно, что при вычислении  $\mathbf{X}_{B_k} = \mathbf{X}_k + \mathbf{X}_{L+2-k} = U_k U_k^H \mathbf{X} + U_{L+2-k} U_{L+2-k}^H \mathbf{X}$ , воспроизводится разложение Фурье для  $K$  векторов матрицы  $\mathbf{X}$ . Затем вычисляется диагональное усреднение  $\mathbf{X}_{B_k}$ . А именно, CiSSA можно представить так:

1. Вычисляем разложение Фурье для каждого вектора вложения  $L$ -траекторной матрицы  $\mathbf{X}$ , состоящей из  $K = N - L + 1$  векторов. Получается  $K$  разложений Фурье по частотам  $w_k = \frac{k-1}{L}$ ,  $k = 1 : \lfloor \frac{L+1}{2} \rfloor$ ;
2. По получившимся разложениям Фурье усредняем значения для соответствующих  $x_i$  и частот  $w_k$ .

### 3.2.2. Точная разделимость

В разделе 1.2.4 обсуждалась запись точной разделимости и асимптотической через частотную разделимость для базового SSA. Для CiSSA введем точную разделимость также через периодограмму.

**Определение 17.** Если носители периодограмм отрезков ряда  $\mathbf{X}_N^{(1)}$  длины  $L$  не пересекаются с носителями периодограмм отрезков ряда  $\mathbf{X}_N^{(2)}$  длины  $L$ , то ряды  $\mathbf{X}_N^{(1)}$  и  $\mathbf{X}_N^{(2)}$  точно разделимы методом CiSSA.

Определение 17 объяснимо тем, что поскольку данный метод является аналогом разложения Фурье, то в смысле сильной разделимости можно точно разделить ряд, в котором одной из компонент является  $\cos(2\pi\omega + \varphi)$  с частотой  $\omega$  такой, что  $L\omega = k \in \mathbb{N}$ , или константа. Для сравнения, при применении базового SSA, условие накладывалось не только на  $L\omega \in \mathbb{N}$ , но и на  $K\omega \in \mathbb{N}$ .

Поэтому до применения алгоритма необходимо выделить интересующие частоты, то есть знать их заранее, и, исходя из них, выбирать значение  $L$ .

### 3.2.3. Асимптотическая разделимость

Аналогично точной разделимости, определим асимптотическую для CiSSA через периодограмму.

**Определение 18.** Если спектральные коэффициенты корреляции отрезков ряда  $\mathbf{X}^{(1)}$  длины  $L = L(N)$  и отрезков ряда  $\mathbf{X}^{(2)}$  длины  $L$  равномерно стремятся к нулю при  $N \rightarrow \infty$ , то ряды  $\mathbf{X}^{(1)}$  и  $\mathbf{X}^{(2)}$  асимптотически разделимы методом CiSSA.

### 3.2.4. Выбор длины окна

Фиксируем временной ряд  $\mathbf{X} = (x_1, \dots, x_N)$  длины  $N$ , а также набор интересных частот  $\Omega = \{\omega_k : \omega_k \in [0, 0.5]\}$  и соответствующие диапазоны для них:  $\bigcup_{j=1}^m \Omega_j = \bigcup_{j=1}^m [\omega_j^{(l)}, \omega_j^{(r)}] = [0, 0.5]$ . Будем рассматривать только случаи, когда  $L\omega_k \in \mathbb{R}$  для любого  $\omega_k \in \Omega$ , а также нет шума.

Возникает вопрос: какое  $L$  лучше выбрать? Если ряд состоит только из синусов и косинусов, то по условиям точной разделимости разницы нет, ошибка всегда будет нулевая. Однако, если это не так, то из всех возможных  $L$  нужно выбирать наименьшее подходящее, поскольку чем оно меньше, тем более локальные свойства CiSSA будет извлекать из ряда.

В подтверждение этому рассмотрим пример  $\mathbf{X} = \mathbf{X}_{e \cdot \sin} + \mathbf{X}_{e \cdot \cos} = e^{A_1 n} \sin(2\pi\omega_1 n) + e^{A_2 n} \cos(2\pi\omega_2 n)$  с  $A_1 = 200$ ,  $A_2 = 100$ ,  $\omega_1 = \frac{1}{12}$ ,  $\omega_2 = \frac{1}{3}$ ,  $N = 96 \cdot 2$ . Будем следить за ошибкой в зависимости от длины окна. В качестве  $L$  рассмотрим значения, кратные частотам компонентам сигнала. Конкретнее,  $L = 12, 24, 36, 48, 60, 72, 84, 96, 192$ .




Рис. 3.3. MSE разделения CiSSA ряда  $\mathbf{X} = \mathbf{X}_{e \cdot \sin} + \mathbf{X}_{e \cdot \cos}$  в зависимости от длины окна  $L$



Рисунок 3.3 наглядно показывает, что при фиксированном  $N$  и с ростом  $L$  ошибка увеличивается. При этом, максимума ошибка достигает при  $L = 192$ , что соответствует обычному применению преобразования Фурье.

### 3.3. Обзор литературы

В данной секции рассмотрены применения CiSSA на практике.

#### 3.3.1. Cognitive Load Detection through EEG Lead-Wise Feature Optimization and Ensemble Classification

В статье [13] рассматриваются несколько наборов данных ЭЭГ под различной нагрузкой, два из которых наиболее значимы:

- **MAT (Mental Arithmetic Task)**: участие студентов в задаче на математический счёт.
- **STEW (Simultaneous Task EEG Workload)**: параллельное выполнение нескольких заданий.

Задача исследования заключалась в следующем:

- С помощью метода CiSSA (и других различных методов) разлагают исходные сигналы ЭЭГ на несколько компонент, каждая из которых несёт информацию о разных частотных диапазонах и временных структурах.
- После разложения из полученных компонент (или их комбинаций) вычисляют числовые признаки: энергетические, энтропийные и другие.
- Эти признаки затем подают на вход классификатору (например,  $k$ NN, SVM или другому алгоритму машинного обучения), чтобы автоматически определить уровень когнитивной нагрузки. Классификация может быть как бинарной (наличие/отсутствие нагрузки), так и многоуровневой (лёгкая/средняя/высокая нагрузка).

Таким образом, метод CiSSA был выбран в качестве одного из подходов разложения сигнала по частотам.

Выводом исследования является таблица 5 статьи [13], в которой авторы сравнивают по метрикам различные решения задачи. Подходы, связанные с CiSSA, являются не самыми наилучшими.

### 3.3.2. Application of visual stratigraphy from line-scan images to constrain chronology and melt features of a firn core from coastal Antarctica

В работе [2] исследовалось таяние ледников, а также анализировались данные визуальной стратиграфии (VS) для построения хронологии фирнового керна из прибрежной Антарктиды. Основной задачей было отделение долгосрочного тренда, связанного с изменением плотности фирна, от сезонных сигналов, обусловленных включениями пыли и морской соли. Для разложения сигнала по частотам был выбран алгоритм CiSSA. Длина окна была установлена равной 10, поскольку «дальнейшее её увеличение не оказывало существенного влияния на результаты».

**Ключевые этапы анализа:**

- **Первая компонента (RC1):** отвечала за долгосрочный тренд, связанный с постепенным увеличением плотности фирна с глубиной;
- **Компоненты со второй по пятую (RC2-RC5):** отражали сезонность, обусловленную изменениями в содержании пыли и морских солей;
- **Остальные компоненты:** содержали шумовой сигнал и не учитывались в дальнейшем анализе.

Таким образом, метод CiSSA был использован как инструмент частотного разложения.

### 3.3.3. Выводы

В рассмотренных работах CiSSA используется как прикладной инструмент для разделения сигнала по частотам. В работе [13] это конкретные частоты, а для [2] это ин-

струмент для выделения тренда. По целям использования алгоритмов, можно сделать вывод, что с таким же успехом можно было применить базовый SSA с автоматической группировкой по компонентам, как сказано в секции 1.2.5.

## Глава 4

## Метод Functional singular spectrum analysis (FSSA)

Functional SSA – метод, предложенный для анализа функциональных временных рядов [10]. Предлагается объединить теорию многомерного функционального анализа главных компонент (MFPCA) и SSA.

Авторы метода FSSA сравнивают его с MSSA и динамическим функциональным анализом главных компонент (dFPCA), показывая преимущество использования FSSA в разделении компонент функциональных данных, особенно для нестационарных рядов.

В данном разделе преимущественно используются обозначения из статьи [10] авторов метода.

Рассмотрим, основные определения.

- **Функциональный временной ряд:**  $\mathbf{y}_N = (y_1, \dots, y_N)^\top$ , длина  $N$ ,  $y_i : [0, 1] \rightarrow \mathbb{R}$ ,  $y_i \in \mathbb{H} = \mathcal{L}^2([0, 1])$  с  $\langle x, y \rangle = \int_0^1 x(s)y(s)ds$ .
- **Пространство  $\mathbb{H}^k$ :** Декартово произведение  $k$  копий  $\mathbb{H}$ .  
Элемент  $\mathbf{x} \in \mathbb{H}^k$ :  $\mathbf{x}(s) = (x_1(s), \dots, x_k(s))^\top$ ,  $x_i \in \mathbb{H}$ ,  $s \in [0, 1]$ . Скалярное произведение:  $\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbb{H}^k} = \sum_{i=1}^k \langle x_i, y_i \rangle$ .
- **Тензорное произведение:** Для  $x \in \mathbb{H}_1$ ,  $y \in \mathbb{H}_2$ , оператор  $x \otimes y : \mathbb{H}_1 \rightarrow \mathbb{H}_2$ ,  $(x \otimes y)h = \langle x, h \rangle y$ ,  $h \in \mathbb{H}_1$ .
- **Пространство  $\mathbb{H}^{L \times K}$ :** Линейное пространство операторов  $\mathcal{Z} : \mathbb{R}^K \rightarrow \mathbb{H}^L$ , заданных  $[z_{i,j}]_{i=1, \dots, L}^{j=1, \dots, K}$ ,

$$\mathcal{Z}\mathbf{a} = \begin{pmatrix} \sum_{j=1}^K a_j z_{1,j} \\ \vdots \\ \sum_{j=1}^K a_j z_{L,j} \end{pmatrix}, \quad z_{i,j} \in \mathbb{H}, \quad \mathbf{a} = (a_1, \dots, a_K) \in \mathbb{R}^K. \quad (4.1)$$

## 4.1. Алгоритм FSSA

Алгоритм схож по структуре с базовым SSA.

Для целого числа  $1 \leq L \leq N/2$  положим  $K = N - L + 1$  и определим множество многомерных функциональных векторов в  $\mathbb{H}^L$  как

$$\mathbf{x}_j(s) := \left( y_j(s), y_{j+1}(s), \dots, y_{j+L-1}(s) \right)^\top, \quad j = 1, \dots, K, \quad (4.2)$$

где  $\mathbf{x}_j$  обозначают функциональные  $L$ -сдвинутые векторы. Следующий алгоритм предоставляет результаты FSSA в четыре этапа.

### Вложение

Траекторный оператор  $\mathcal{X} : \mathbb{R}^K \rightarrow \mathbb{H}^L$ .

$$\mathcal{X}\mathbf{a} := \sum_{j=1}^K a_j \mathbf{x}_j = \begin{pmatrix} \sum_{j=1}^K a_j y_j \\ \sum_{j=1}^K a_j y_{j+1} \\ \vdots \\ \sum_{j=1}^K a_j y_{j+L-1} \end{pmatrix}, \quad \mathbf{a} = (a_1, \dots, a_K)^\top \in \mathbb{R}^K. \quad (4.3)$$

Кроме того,  $\mathcal{X} = \mathcal{T}\mathbf{y}_N$ , где  $\mathcal{T}$  — оператор из  $\mathbb{H}^N$  в  $\mathbb{H}_H^{L \times K}$ . Вычисление  $\mathcal{X}\mathbf{a}$  в заданной точке  $s \in [0, 1]$  эквивалентно матричному произведению  $\mathbf{X}(s)\mathbf{a}$ , где  $\mathbf{X}(s)$  — это  $L \times K$  ганкелева матрица, заданная как

$$\mathbf{X}(s) = \begin{bmatrix} \mathbf{x}_1(s), \dots, \mathbf{x}_K(s) \end{bmatrix}. \quad (4.4)$$

Оператор  $\mathcal{X}$  является ограниченным линейным оператором. Если определить  $\mathcal{X}^* : \mathbb{H}^L \rightarrow \mathbb{R}^K$  как

$$\mathcal{X}^*\mathbf{z} = \begin{pmatrix} \sum_{i=1}^L \langle y_i, z_i \rangle \\ \sum_{i=1}^L \langle y_{i+1}, z_i \rangle \\ \vdots \\ \sum_{i=1}^L \langle y_{i+K-1}, z_i \rangle \end{pmatrix}, \quad \mathbf{z} = (z_1, \dots, z_L)^\top \in \mathbb{H}^L, \quad (4.5)$$

то  $\mathcal{X}^*$  является сопряжённым оператором для  $\mathcal{X}$ .

### Разложение

Определим оператор  $\mathcal{S} : \mathbb{H}^L \rightarrow \mathbb{H}^L$  как  $\mathcal{S} := \mathcal{X}\mathcal{X}^*$ . Следовательно, для заданного  $\mathbf{z} \in \mathbb{H}^L$  это означает, что

$$\mathcal{S}\mathbf{z} = \sum_{j=1}^K \sum_{i=1}^L \langle y_{i+j-1}, z_i \rangle \mathbf{x}_j = \sum_{j=1}^K \langle \mathbf{x}_j, \mathbf{z} \rangle_{\mathbb{H}^L} \mathbf{x}_j = \sum_{j=1}^K (\mathbf{x}_j \otimes \mathbf{x}_j) \mathbf{z}. \quad (4.6)$$

Для любого положительного  $i$  определим оператор  $\mathcal{X}_i : \mathbb{R}^K \rightarrow \mathbb{H}^L$ , заданный как

$$\mathcal{X}_i \mathbf{a} := \sum_{j=1}^K a_j (\boldsymbol{\psi}_i \otimes \boldsymbol{\psi}_i) \mathbf{x}_j = (\boldsymbol{\psi}_i \otimes \boldsymbol{\psi}_i) \sum_{j=1}^K a_j \mathbf{x}_j. \quad (4.7)$$

$\mathcal{X}_i$  — элементарный оператор. Вычисление  $\mathcal{X}_i \mathbf{a}$  в заданной точке  $s \in [0, 1]$  эквивалентно матричному произведению  $\mathbf{X}_i(s) \mathbf{a}$ , где  $\mathbf{X}_i(s)$  — это  $L \times K$  матрица, заданная как

$$\begin{aligned} \mathbf{X}_i(s) &:= \left[ \langle \boldsymbol{\psi}_i, \mathbf{x}_1 \rangle_{\mathbb{H}^L} \boldsymbol{\psi}_i(s), \dots, \langle \boldsymbol{\psi}_i, \mathbf{x}_K \rangle_{\mathbb{H}^L} \boldsymbol{\psi}_i(s) \right] \\ &= \left[ (\boldsymbol{\psi}_i \otimes \boldsymbol{\psi}_i) \mathbf{x}_1(s), \dots, (\boldsymbol{\psi}_i \otimes \boldsymbol{\psi}_i) \mathbf{x}_K(s) \right]. \end{aligned} \quad (4.8)$$

Элементарные операторы  $\mathcal{X}_i$  являются ограниченными операторами ранга один. Кроме того,  $\mathcal{X}_i$  декомпозируют траекторный оператор  $\mathcal{X}$  как

$$\mathcal{X} = \sum_{i=1}^{\infty} \mathcal{X}_i. \quad (4.9)$$

Следующая теорема предоставляет сингулярное разложение (SVD) траекторного оператора  $\mathcal{X}$  для получения соответствующих собственных троек  $(\sqrt{\lambda_i}, \mathbf{v}_i, \boldsymbol{\psi}_i)$  на этапе декомпозиции [10].

**Теорема 4.** Пусть  $\{\boldsymbol{\psi}_i\}_{i=1}^{\infty}$  и  $\{\lambda_i\}_{i=1}^{\infty}$  — собственные элементы  $\mathcal{S}$ , и

$$\mathcal{S}^\dagger := \mathcal{X}^* \mathcal{X} = \begin{bmatrix} \sum_{i=1}^L \langle y_i, y_i \rangle & \cdots & \sum_{i=1}^L \langle y_i, y_{i+K-1} \rangle \\ \vdots & \ddots & \vdots \\ \sum_{i=1}^L \langle y_{i+K-1}, y_i \rangle & \cdots & \sum_{i=1}^L \langle y_{i+K-1}, y_{i+K-1} \rangle \end{bmatrix}. \quad (4.10)$$

Тогда сингулярное разложение траекторного оператора  $\mathcal{X}$  можно записать как

$$\mathcal{X} = \sum_{i=1}^{\infty} \sqrt{\lambda_i} \mathbf{v}_i \otimes \boldsymbol{\psi}_i, \quad (4.11)$$

где  $\mathbf{v}_i = \left( \frac{\langle \boldsymbol{\psi}_i, \mathbf{x}_1 \rangle_{\mathbb{H}^L}}{\sqrt{\lambda_i}}, \dots, \frac{\langle \boldsymbol{\psi}_i, \mathbf{x}_K \rangle_{\mathbb{H}^L}}{\sqrt{\lambda_i}} \right)^\top$ . Кроме того, для любого  $\mathbf{a} \in \mathbb{R}^K$ , используя (4.11), мы имеем

$$\mathcal{X} \mathbf{a} = \sum_{i=1}^{\infty} \sqrt{\lambda_i} \langle \mathbf{v}_i, \mathbf{a} \rangle_{\mathbb{R}^K} \boldsymbol{\psi}_i, \quad (4.12)$$

где

- i)  $\{\lambda_i\}_{i=1}^{\infty}$  — множество неубывающих собственных значений  $\mathcal{S}^\dagger$ , и
- ii)  $\mathbf{v}_i$  — соответствующие ортонормированные собственные векторы  $\mathcal{S}^\dagger$ , удовлетворяющие  $\mathcal{X} \mathbf{v}_i = \sqrt{\lambda_i} \boldsymbol{\psi}_i$ .

## Группировка

Аналогично базовому SSA. Получается

$$\mathcal{X} = \mathcal{X}_{I_1} + \mathcal{X}_{I_2} + \dots + \mathcal{X}_{I_m}. \quad (4.13)$$

## Диагональное усреднение

Для заданного  $q$  ( $1 \leq q \leq m$ ) используется  $\mathcal{T}^{-1} : \mathbb{H}_H^{L \times K} \rightarrow \mathbb{H}^N$  для преобразования оператора  $\mathcal{X}_{I_q}$  из (4.13) в  $\tilde{\mathbf{y}}_N^q$ .

Поскольку  $\mathcal{X}_{I_q} \in \mathbb{H}^{L \times K}$ , сначала выполняется проекция на  $\mathbb{H}_H^{L \times K}$ , замкнутое подпространство  $\mathbb{H}^{L \times K}$ .

Элементы  $\mathcal{X}_{I_q}$  и  $\tilde{\mathcal{X}}_{I_q}$  обозначаются  $[x_{i,j}^q]$  и  $[\tilde{x}_{i,j}^q]$ . Метод диагонального усреднения обобщается на  $\mathbb{H}^{L \times K}$ , где

$$\tilde{x}_{i,j}^q = \frac{1}{n_s} \sum_{(l,k): l+k=s} x_{l,k}^q, \quad (4.14)$$

$s = i + j$ ,  $n_s$  — число пар  $(l, k)$ , таких что  $l + k = s$ . Проекция обозначается  $\Pi_{\mathbb{H}} : \mathbb{H}^{L \times K} \rightarrow \mathbb{H}_H^{L \times K}$ , и  $\tilde{\mathcal{X}}_{I_q} = \Pi_{\mathbb{H}} \mathcal{X}_{I_q}$ .

Как итог:  $\tilde{\mathbf{y}}_N^q = \mathcal{T}^{-1} \tilde{\mathcal{X}}_{I_q}$ .

## 4.2. Практическая реализация алгоритма FSSA

Для использования на практике алгоритма FSSA, нужно понять, как использовать дискретные данные с теорией, основанной на непрерывности по  $s$ . Делается это следующим образом: дискретные данные  $\{y_j(t_k)\}_{j=1, \dots, N}$  преобразуются в функции  $y_j(s) \in \mathbb{H}$  на  $[0, 1]$  с использованием базисного разложения:

$$y_j(s) = \sum_{i=1}^d a_{i,j} \nu_i(s),$$

где  $\{\nu_i\}_{i=1}^d$  — базис (например, В-сплайны),  $d$  определяется кросс-валидацией. Получается функциональный временной ряд  $\mathbf{y}_N = \{y_1(s), \dots, y_N(s)\}$ .

## Вложение

Задаётся  $L$ . Формируются векторы:

$$\mathbf{x}_j(s) = (y_j(s), \dots, y_{j+L-1}(s))^\top, \quad j = 1, \dots, K, \quad K = N - L + 1.$$

Траекторный оператор  $\mathcal{X} : \mathbb{R}^K \rightarrow \mathbb{H}^L$  представлен матрицей  $\mathbf{X}(s) = [\mathbf{x}_1(s), \dots, \mathbf{x}_K(s)]$ , вычисляемой через базисные коэффициенты  $a_{i,j}$ .

## Разложение

Вычисляется оператор  $\mathcal{S} = \mathcal{X}\mathcal{X}^*$ , представленный матрицей  $\mathbf{S}$  в базисе  $\mathbb{H}_d^L$ . Формируется базис  $\{\phi_k\}_{k=1}^{Ld}$ , где  $\phi_k$  — вектор с  $\nu_{q_k}$  на позиции  $r_k$ ,  $k = (q_k - 1)L + r_k$ . Вычисляются матрицы:

$$\mathbf{G} = [\delta_{r_i, r_j} \langle \nu_{q_i}, \nu_{q_j} \rangle]_{i,j=1}^{Ld}, \quad \mathbf{S}_0 = \left[ \sum_{m=1}^K \langle y_{r_i+m-1}, \nu_{q_i} \rangle \langle y_{r_j+m-1}, \nu_{q_j} \rangle \right]_{i,j=1}^{Ld}.$$

$$\mathbf{S} = \mathbf{G}^{-1} \mathbf{S}_0.$$

Находятся собственные значения  $\lambda_i$  и векторы  $\mathbf{c}_{\psi_i}$  матрицы  $\mathbf{S}$ . Собственные функции:  $\psi_i = \sum_{k=1}^{Ld} (\mathbf{c}_{\psi_i})_k \phi_k$ . Вычисляются элементарные операторы  $\mathcal{X}_i = (\psi_i \otimes \psi_i) \mathcal{X}$ .

## Группировка

Аналогично теоретической группировке.

## Реконструкция

Для  $\mathcal{X}_{I_q}$  выполняется диагональное усреднение:

$$\tilde{x}_{i,j}^q = \frac{1}{n_s} \sum_{(l,k): l+k=i+j} x_{l,k}^q,$$

где  $x_{l,k}^q$  — элементы  $\mathcal{X}_{I_q}$ , получая  $\tilde{\mathcal{X}}_{I_q} = \Pi_{\mathbb{H}} \mathcal{X}_{I_q}$ . Применяется  $\mathcal{T}^{-1}$ :  $\tilde{\mathbf{y}}_N^q = \mathcal{T}^{-1} \tilde{\mathcal{X}}_{I_q}$ , выраженное через базисные коэффициенты.



### 4.3. Разделимость

Рассматривается  $\mathbf{y}_N = \mathbf{y}_N^{(1)} + \mathbf{y}_N^{(2)}$ , где  $\mathbf{y}_N^{(i)} = \{y_1^{(i)}, \dots, y_N^{(i)}\}$ ,  $i = 1, 2$ , — функциональные временные ряды (FTS). Для фиксированной длины окна  $L$  для каждого ряда  $\mathbf{y}_N^{(i)}$  обозначается  $\{\mathbf{x}_k^{(i)}\}_{k=1}^K$  — последовательность функциональных сдвинутых векторов,  $\mathcal{L}^{(i)}$  — линейное пространство, порождённое  $\{\mathbf{x}_k^{(i)}\}_{k=1}^K$ . Разделимость рядов  $\mathbf{y}_N^{(1)}$  и  $\mathbf{y}_N^{(2)}$  эквивалентна  $\mathcal{L}^{(1)} \perp \mathcal{L}^{(2)}$ , то есть  $\langle \mathbf{x}_k^{(1)}, \mathbf{x}_{k'}^{(2)} \rangle_{\mathbb{H}^L} = 0$  для всех  $k, k' = 1, \dots, K$ .

Необходимое условие разделимости определяется через w-корреляцию. Взвешенное скалярное произведение рядов  $\mathbf{y}_N^{(1)}$  и  $\mathbf{y}_N^{(2)}$  задаётся как

$$\langle \mathbf{y}_N^{(1)}, \mathbf{y}_N^{(2)} \rangle_w = \sum_{i=1}^N w_i \langle y_i^{(1)}, y_i^{(2)} \rangle, \quad (4.15)$$

где  $w_i = \min\{i, L, N - i + 1\}$ . Ряды  $\mathbf{y}_N^{(1)}$  и  $\mathbf{y}_N^{(2)}$  называются w-ортогональными, если

$$\langle \mathbf{y}_N^{(1)}, \mathbf{y}_N^{(2)} \rangle_w = 0. \quad (4.16)$$

**Теорема 5.** Разделимость рядов  $\mathbf{y}_N^{(1)}$  и  $\mathbf{y}_N^{(2)}$  влечёт их w-ортогональность [10].

## Глава 5

## Сравнения алгоритмов

## 5.1. Сравнение SSA и GSSA

В данном разделе сравниваются алгоритмы базового SSA и GSSA с параметром  $\alpha \neq 0$ . Все вычисления, а также код метода GSSA можно найти в репозитории [11].

## 5.1.1. Линейные фильтры

Чтобы понять их принципиальное отличие, рассмотрим методы с точки зрения линейных фильтров: по представлениям (1.4) и (2.2) можно построить амплитудно-частотные характеристики.

Рассмотрим временной ряд  $X = \sin\left(\frac{2\pi}{12}x\right)$ ,  $N = 96 \cdot 2 - 1$ ,  $L = 48$ . Построим АЧХ для  $\alpha$  равных 0 (базовый SSA),  $\frac{1}{2}$ , 1, 2:




Рис. 5.1. АЧХ фильтров, отвечающих за  $X = \sin\left(\frac{2\pi}{12}x\right)$ , при разных  $\alpha$

На рисунке 5.1 показано, как фильтры ведут себя для различных значений параметра  $\alpha$ . Для всех рассмотренных значений  $\alpha$  фильтры подавляют частоты, значительно отличающиеся от частоты синуса  $\omega = \frac{1}{12}$ . При малых значениях  $\alpha$ , таких как  $\alpha = 0$ , наблюдается волнообразное поведение фильтра, что указывает на частичное захватывание соседних частот, хотя и не близких к частоте синуса. С увеличением  $\alpha$  это волнообразное поведение уменьшается, и фильтр начинает захватывать больше частот, максимально близких к  $\frac{1}{12}$ .

Таким образом, метод **GSSA** должен работать лучше **SSA** в случае, когда в временном ряде содержится пара периодических функций, частота одной из которых попадает в вершину волны АЧХ фильтра для другой функции. Например, добавим к  $X_{\sin} = \sin\left(\frac{2\pi}{12}n\right)$  косинус с частотой  $\frac{1}{19}$ . Тогда  $X = X_{\sin} + X_{\cos} = \sin\left(\frac{2\pi}{12}n\right) + \frac{1}{2}\cos\left(\frac{2\pi}{19}n\right)$ , и можем рассмотреть АЧХ, отвечающие за синус, при базовом **SSA** ( $\alpha = 0$ ) и **GSSA** при  $\alpha = \frac{1}{2}$ . При этом,  $N = 96 \cdot 2 - 1$ ,  $L = 48$ .




Рис. 5.2. Ряд  $X = X_{\sin} + X_{\cos}$ . АЧХ фильтров, отвечающих за  $X_{\sin} = \sin\left(\frac{2\pi}{12}n\right)$ , при разных  $\alpha$

По рисунку 5.2 заметно, что фильтр для синуса в базовом **SSA** также частично захватит периодику с частотой  $\frac{1}{19}$ , в то время, как **GSSA** не будет испытывать таких проблем.

### 5.1.2. Фильтры в различных точках

В зависимости от точек ряда, линейные фильтры будут отличаться друг от друга. Рассмотрим тот же пример  $X = X_{\sin} + X_{\cos} + X_{\text{noise}} = \sin\left(\frac{2\pi}{12}x\right) + \frac{1}{2}\cos\left(\frac{2\pi}{19}x\right) + \varepsilon_n$ , где  $\varepsilon_n \sim N(0, 0.1^2)$ .

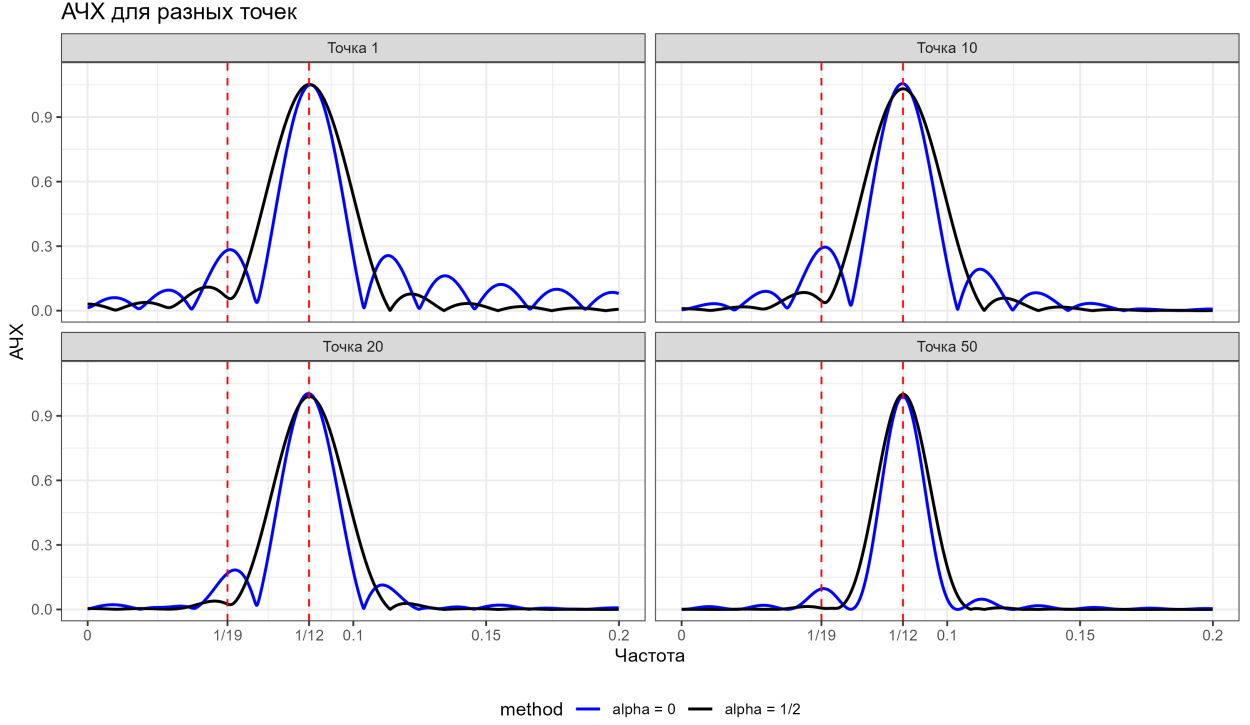


Рис. 5.3. Ряд  $X = X_{\sin} + X_{\cos} + X_{\text{noise}}$ . АЧХ фильтров в разных точках, отвечающих за  $X_{\sin} = \sin\left(\frac{2\pi}{12}n\right)$ , при разных  $\alpha$

По рисунку 5.3 видно, что когда точка  $s$  приближается по времени к средним точкам временного ряда ( $L \leq s \leq K$ ), полоса пропускания фильтра становится уже, а также фильтр начинает все меньше и меньше захватывать соседние частоты.

Для этого примера также можно посмотреть на график средней MSE ошибки в зависимости от точки ряда. Эксперимент проводился 1000 раз.

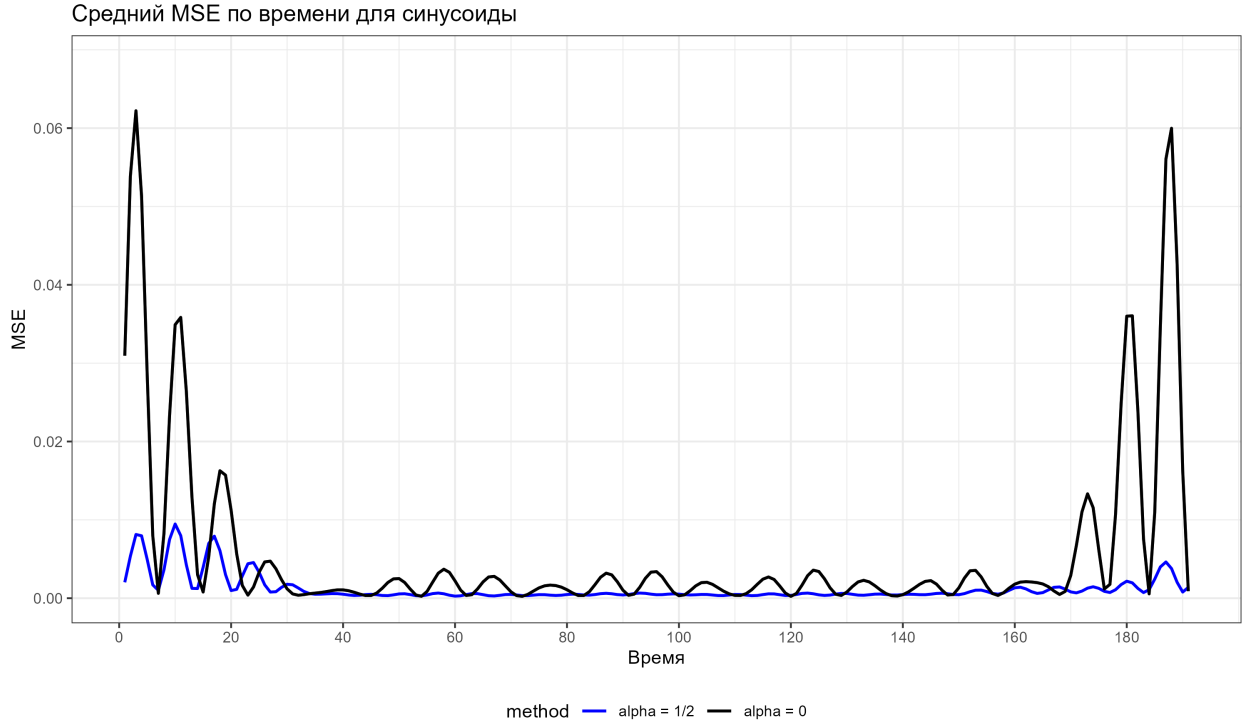


Рис. 5.4. Ряд  $X = X_{\sin} + X_{\cos} + X_{\text{noise}}$ . MSE ошибки выделения синуса в зависимости от точки ряда

Таким образом, можно сделать вывод, что разделимость также зависит от точки ряда. В средних точках достигаются наилучшие значения ошибки. Однако это не означает, что нужно брать маленькое  $L$ , поскольку чем больше длина окна, тем лучше происходит разделение компонент между собой в целом [5].

### 5.1.3. Отделение сигнала от шума

Теперь посмотрим на общую ошибку для примера  $X = X_{\sin} + X_{\cos}$ :

Таблица 5.1. MSE разложений ряда  $X = X_{\sin} + X_{\cos}$  для SSA и GSSA с  $\alpha = \frac{1}{2}$

Метод/Ошибка	$X_{\sin}$	$X_{\cos}$	$X$
<b>SSA</b>	5.15e-03	5.15e-03	<b>6.01e-30</b>
<b>GSSA, <math>\alpha = 0.5</math></b>	<b>3.68e-04</b>	<b>3.68e-04</b>	<b>9.53e-30</b>

Как видно из таблицы 5.1, GSSA справился с разделением на порядок лучше SSA.

Однако, у **GSSA** есть другая проблема. Если добавить к ряду шум, то оба алгоритма будут воспринимать этот шум как что-то близкое к частотам периодик, содержащихся в исходном ряде. А поскольку **GSSA** захватывает больше частот, максимально близких к периодикам, то и больше шума попадет в компоненты, отвечающие за периодики.

Добавим к  $\mathbf{X}$  шумовую компоненту:  $\mathbf{X} = \mathbf{X}_{\sin} + \mathbf{X}_{\cos} + \mathbf{X}_{\text{noise}} = \sin\left(\frac{2\pi}{12}x\right) + \frac{1}{2}\cos\left(\frac{2\pi}{19}x\right) + \varepsilon_n$ , где  $\varepsilon_n \sim N(0, 0.1^2)$ ,  $N = 96 \cdot 2 - 1$ ,  $L = 48$ . Проводилось 100 тестов, в таблице 5.2 указаны средние значения ошибки для одних и тех же реализаций шума.

Таблица 5.2. MSE разложений ряда  $\mathbf{X} = \mathbf{X}_{\sin} + \mathbf{X}_{\cos} + \mathbf{X}_{\text{noise}}$  для **SSA** и **GSSA** с  $\alpha = \frac{1}{2}$

Метод	$\mathbf{X}_{\sin}$	$\mathbf{X}_{\cos}$	$\mathbf{X}$
<b>SSA</b>	5.68e-03	5.44e-03	<b>7.48e-04</b>
<b>GSSA</b> , $\alpha = \frac{1}{2}$	<b>1.21e-03</b>	<b>1.25e-03</b>	1.04e-03

По таблице 5.2 видно, что **GSSA** все же справился лучше **SSA**, однако порядок ошибки теперь одинаковый для рассмотрения косинуса или синуса. Но при этом, отделение сигнала от шума получилось лучше у **SSA**. Также был проведен парный t-критерий для зависимых выборок с целью проверки гипотезы о равенстве средних значений ошибки для каждой компоненты. В качестве нулевой гипотезы ( $H_0$ ) предполагалось, что средние значения двух сравниваемых выборок равны. Критический уровень значимости был установлен на уровне  $\alpha_{\text{hypothesis}} = 0.05$ . Результаты анализа показали, что во всех случаях  $p$ -значение оказалось меньше 0.05, что позволяет отвергнуть нулевую гипотезу.

#### 5.1.4. Вложенный вариант

Сингулярное разложение матрицы обладает наилучшими аппроксимационными свойствами в смысле минимизации нормы Фробениуса (или спектральной нормы) для заданного ранга. Из этого следует, что разложение матрицы  $\mathbf{S} = \mathbf{X}\mathbf{X}^T$  методом SVD будет наилучшим образом отделять сигнал от шума.

По результатам сравнений методов из таблиц 5.1 и 5.2, а также предыдущих рассуждений, получается, что есть смысл использовать базовый **SSA** для выделения сигнала, а уже сам сигнал разделять на различные компоненты с помощью **GSSA**.

Рассмотрим  $X = X_{\sin} + X_{\cos} + X_{\text{noise}} = \sin\left(\frac{2\pi}{12}x\right) + \frac{1}{2}\cos\left(\frac{2\pi}{19}x\right) + \varepsilon_n$ , где  $\varepsilon_n \sim N(0, 0.1^2)$ , только теперь сначала применим **SSA**, а затем **GSSA**. Получится вложенный вариант.  $N = 96 \cdot 2 - 1$ ,  $L = 48$  для обоих методов.

Таблица 5.3.  $X_{\sin} + X_{\cos} + \varepsilon_n$ ,  $\varepsilon_n \sim N(0, 0.1^2)$ , MSE оценок

Метод/Ошибка	$X_{\sin}$	$X_{\cos}$	$X$
<b>SSA</b>	5.68e-03	5.44e-03	<b>7.48e-04</b>
<b>GSSA</b> , $\alpha = 0.5$	<b>1.21e-03</b>	<b>1.25e-03</b>	1.04e-03
<b>SSA + GSSA</b> , $\alpha = 0.5$	<b>1.06e-03</b>	<b>1.12e-03</b>	<b>7.15e-04</b>

Анализ данных, представленных в таблице 5.3, позволяет сделать вывод, что комбинирование алгоритмов привело к улучшению как в выделении полезного сигнала, так и в разделении компонент между собой. Полученные результаты демонстрируют более высокую точность по сравнению с данными, приведёнными в таблице 5.2.

Таким образом, по приведенным примерам можно сделать вывод, что **GSSA** позволяет улучшить разделимость периодических компонент ряда. Однако, вместе с тем, разложение будет захватывать больше шума в сравнении с базовым **SSA**.

## 5.2. Различия SSA, CiSSA и Фурье

В данной секции проводится сравнение методов разложения временного ряда: базовый SSA, SSA с использованием EOSSA для улучшения разделимости, разложения Фурье и Фурье с расширением ряда, базового CiSSA и CiSSA с расширением ряда. Все вычисления, а также код метода CiSSA можно найти в репозитории [11]

### 5.2.1. Автоматическая группировка

Авторы статьи [1] выделяют главным преимуществом то, что CiSSA автоматически разделяет компоненты ряда по частотам. Однако есть метод, позволяющий сделать автоматическое объединение частот по периодограмме в методе SSA [8]. При этом, прежде чем применять его, стоит выполнить процедуру улучшения разделимости. В данной работе будут использоваться методы EOSSA и FOSSA [3]. Отсюда следует, что все рассматриваемые в данной секции алгоритмы могут по заранее заданным диапазонам частотам выдать временные ряды, отвечающие за эти диапазоны.

### 5.2.2. Собственные пространства

Каждый алгоритм после группировки порождает собственные подпространства. В случае базового SSA базис подпространств является адаптивным, то есть зависящим от  $X, L, N$ .

В случае CiSSA базис зависит только от  $L, N$ . Если зафиксировать данные параметры, и менять  $X$ , базис никак не поменяется.

На базис разложения Фурье влияет только  $N$ .

### 5.2.3. Точная разделимость

В свойствах методов были приведены классы функций и условия, при которых методы могут безошибочно разделить два ряда друг от друга. Сравним эти условия.

Фиксируем временной ряд  $X = X_1 + X_2 = A_1 \cos(2\pi\omega_1 n + \varphi_1) + A_2 \cos(2\pi\omega_2 n + \varphi_2)$ .



Таблица 5.4. Условия точной разделимости для SSA, SSA EOSSA, Fourier, CiSSA

Метод	Условия точной разделимости
<b>SSA</b>	$L\omega_1, L\omega_2, K\omega_1, K\omega_2 \in \mathbb{N}, \omega_1 \neq \omega_2, A_1 \neq A_2$
<b>SSA EOSSA</b>	$\omega_1 \neq \omega_2$
<b>Fourier</b>	$N\omega_1, N\omega_2 \in \mathbb{N}, \omega_1 \neq \omega_2$
<b>CiSSA</b>	$L\omega_1, L\omega_2 \in \mathbb{N}, \omega_1 \neq \omega_2$

Из таблицы 5.4 видно, что для самые жесткие условия для **SSA**, а наилучшие у **SSA EOSSA**. Для **Fourier** и **CiSSA** условия схожи, однако тут стоит отметить, что длину ряда  $N$  далеко не всегда можно подобрать, в отличие от  $L$ . В этом смысле лучше себя показывает **CiSSA** в сравнении с **Fourier**.

Теперь посмотрим численно, на следующие ситуации: параметры рассматриваемых методов подобраны верно, параметры подобраны плохо, для **CiSSA** и **Fourier** используем расширение ряда.

**Пример.** Будем разделять временной ряд  $X = X_{\sin} + X_{\cos} = \sin \frac{2\pi}{12}n + \frac{1}{2} \cos \frac{2\pi}{3}n$ . Рассмотрим разложения методов в лучшем и худшем случае. Для всех алгоритмов кроме базового **SSA** выделялись периодические компоненты по диапазонам  $(\omega \pm \Delta)$ , где  $\Delta = \frac{1}{N+1}$ ,  $\omega = \frac{1}{12}, \frac{1}{3}$ .

Таблица 5.5. MSE ошибки разложений методов ряда  $X = X_{\sin} + X_{\cos}$  в лучших и худших случаях

Метод	Параметры	MSE( $X_{\sin}$ )	MSE( $X_{\cos}$ )	MSE( $X$ )
SSA	$L = 96, K = 96$ ( $Lw, Kw \in \mathbb{N}$ )	6.8e-30	1.5e-29	1.8e-29
SSA	$L = 96, K = 97$ ( $Lw \in \mathbb{N}, Kw \notin \mathbb{N}$ )	2.2e-06	2.2e-06	2.0e-29
Fourier	$N = 96 \cdot 2$ ( $Nw \in \mathbb{N}$ )	1.7e-28	3.5e-28	5.1e-28
Fourier	$N = 96 \cdot 2 - 1$ ( $Nw \notin \mathbb{N}$ )	9.4e-03	3.5e-03	1.3e-02
Fourier extended	$N = 96 \cdot 2$ ( $Nw \in \mathbb{N}$ )	6.2e-04	2.6e-03	3.2e-03
Fourier extended	$N = 96 \cdot 2 - 1$ ( $Nw \notin \mathbb{N}$ )	1.1e-05	4.9e-04	4.9e-04
CiSSA	$L = 96$ ( $Lw \in \mathbb{N}$ )	1.9e-29	5.3e-30	2.1e-29
CiSSA	$L = 97$ ( $Lw \notin \mathbb{N}$ )	1.7e-02	7.0e-03	2.3e-02
CiSSA extended	$L = 96$ ( $Lw \in \mathbb{N}$ )	2.0e-04	8.6e-04	1.1e-03
CiSSA extended	$L = 97$ ( $Lw \notin \mathbb{N}$ )	2.4e-03	6.9e-04	3.1e-03
SSA EOSSA, $r = 4$	$L = 96, K = 96$ ( $Lw, Kw \in \mathbb{N}$ )	1.5e-29	7.5e-30	2.0e-29
SSA EOSSA, $r = 4$	$L = 96, K = 97$ ( $Lw \in \mathbb{N}, Kw \notin \mathbb{N}$ )	1.5e-29	8.8e-30	1.9e-29

#### 5.2.4. Асимптотическая разделимость

Как было сказано, асимптотически разделимы в методе **SSA** полиномы, гармонические функции (косинус, косинус помноженный на экспоненту) [5].

В алгоритме **CiSSA**, при увеличении длины окна  $L$  и длины ряда  $N$  в бесконечность, меняется сетка разбиения частот. Из-за этого, даже если не удастся выбрать подходящее  $L$ , при котором будет точно отделим косинус, но постоянно его увеличивать, в конечном счете получится снизить ошибку выделения нужной компоненты косинуса, если брать соседние частоты с частотой компоненты. Однако в таком подходе есть две проблемы. Во-первых, в этом случае нужно выбирать диапазон частот, которые стоит объединить. Во-вторых, в реальности это труднореализуемо, слишком большое  $N$  и  $L$  придется выбрать, чтобы значимо снизить ошибку. Поэтому, при использовании **CiSSA** обязательно нужно заранее понимать, какие частоты интересуют. Аналогичная ситуация для разложения Фурье.

Как следствие асимптотической разделимости можно рассмотреть следующий при-

мер:  $\mathbf{X} = \mathbf{X}_{e\text{-sin}} + \mathbf{X}_{e\text{-cos}} = e^{A_1 n} \sin(2\pi\omega_1 n) + e^{A_2 n} \cos(2\pi\omega_2 n)$ .

Таблица 5.6. MSE разложений  $\mathbf{X} = \mathbf{X}_{e\text{-sin}} + \mathbf{X}_{e\text{-cos}}$  в худших и лучших случаях

Метод	Параметры	MSE ( $\mathbf{X}_{e\text{-sin}}$ )	MSE ( $\mathbf{X}_{e\text{-cos}}$ )	MSE ( $\mathbf{X}$ )
SSA	(1) $L\omega_i \in \mathbb{N}, K\omega_i \in \mathbb{N}$	5.3e-05	5.3e-05	<b>1.2e-27</b>
SSA	(5) $L\omega_i \in \mathbb{N}, K\omega_i \notin \mathbb{N}$	4.8e-04	4.8e-04	<b>1.1e-27</b>
Fourier	(3) $N\omega_i \in \mathbb{N}$	6.7e-02	1.4e-02	4.9e-02
Fourier	(7) $N\omega_i \notin \mathbb{N}$	3.7e-02	1.1e-01	1.1e-01
CiSSA	(4) $L\omega_i \in \mathbb{N}$	3.8e-03	2.6e-02	1.5e-02
SSA EOSSA	(2) $L\omega_i \in \mathbb{N}, K\omega_i \in \mathbb{N}, r = 4$	<b>3.0e-28</b>	<b>4.4e-28</b>	<b>7.4e-29</b>
SSA EOSSA	(6) $L\omega_i \in \mathbb{N}, K\omega_i \notin \mathbb{N}, r = 4$	<b>2.8e-28</b>	<b>4.2e-28</b>	<b>7.5e-29</b>

Для параметров таблицы 5.6 выбраны такие значения:

Таблица 5.7. Конкретные параметры для таблицы 5.6

Случай	Значения
(1)	$N = 96 \cdot 2 - 1, L = 96, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Группы: $\mathbf{X}_{e\text{-sin}} - [1, 2]; \mathbf{X}_{e\text{-cos}} - [3, 4]$ .
(2)	$N = 96 \cdot 2 - 1, L = 96, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Частоты: $\mathbf{X}_{e\text{-sin}} - [\omega_1 \pm \varepsilon]; \mathbf{X}_{e\text{-cos}} - [\omega_2 \pm \varepsilon], \varepsilon = 1/L$ .
(3)	$N = 96 \cdot 2, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Частоты: $\mathbf{X}_{e\text{-sin}} - [\omega_1 \pm \varepsilon]; \mathbf{X}_{e\text{-cos}} - [\omega_2 \pm \varepsilon], \varepsilon = 1/N$ .
(4)	$N = 96 \cdot 2 - 1, L = 96, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Частоты: $\mathbf{X}_{e\text{-sin}} - [\omega_1 \pm \varepsilon]; \mathbf{X}_{e\text{-cos}} - [\omega_2 \pm \varepsilon], \varepsilon = 1/L$ .
(5)	$N = 96 \cdot 2 - 2, L = 96, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Группы: $\mathbf{X}_{e\text{-sin}} - [1, 2]; \mathbf{X}_{e\text{-cos}} - [3, 4]$ .
(6)	$N = 96 \cdot 2 - 2, L = 96, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Частоты: $\mathbf{X}_{e\text{-sin}} - [\omega_1 \pm \varepsilon]; \mathbf{X}_{e\text{-cos}} - [\omega_2 \pm \varepsilon], \varepsilon = 1/L$ .
(7)	$N = 96 \cdot 2 - 1, \omega_1 = \frac{1}{12}, \omega_2 = \frac{1}{3}, A_1 = 200, A_2 = 100$ . Частоты: $\mathbf{X}_{e\text{-sin}} - [\omega_1 \pm \varepsilon]; \mathbf{X}_{e\text{-cos}} - [\omega_2 \pm \varepsilon], \varepsilon = 1/N$ .

В таблице 5.6 первая половина является примерами с хорошими параметрами, а вторая – с плохими. Из неё видно, что CiSSA все же разделяет ряды, но не так хорошо, как это делает SSA или тем более SSA с EOSSA.

Однако результатов асимптотической делимости можно достичь только если устремлять и  $N$ , и  $L$  в бесконечность. В реальности такое вряд ли получится сделать. Более того, лучше брать  $L$  настолько маленьким, насколько это возможно. Поскольку CiSSA основан на разложении Фурье и усреднении результатов в соответствующих точках, то это позволяет работать с короткими временными окнами. Разбивая длинный сигнал на короткие сегменты, анализируются локальные спектральные свойства, а не глобальные.

Теперь рассмотрим разложение непериодических компонент. Поскольку все непериодические компоненты относятся к частотам достаточно близким к нулю, то и разделить между собой непериодические компоненты методы CiSSA и Фурье не могут даже асимптотически, в отличие от SSA.

### 5.2.5. Выделение тренда

Рассмотрим, влияние непериодических компонент на разложение ряда.

Базовый алгоритм SSA может выделять трендовую составляющую за счет своего адаптивного базиса. Для алгоритмов CiSSA и разложения Фурье нужно применять процедуры расширения временного ряда, чтобы использовать их для выделения тренда.

**Пример.** Рассмотрим ряд из примера в секции 5.2.3 и добавим к нему тренд.  $X = X_c + X_e + X_{\sin} + X_{\cos} = 1 + e^{\frac{n}{100}} + \sin \frac{2\pi}{12}n + \frac{1}{2} \cos \frac{2\pi}{3}n$ . Кроме того, для всех алгоритмов кроме базового SSA выделялись периодические компоненты по диапазонам  $(\omega \pm \Delta)$ , где  $\Delta = \frac{1}{N+1}$ ,  $\omega = \frac{1}{12}, \frac{1}{3}$ , а непериодичность соответствовала диапазону частот  $[0, \frac{1}{24})$ . Будем искать экспоненту и константу по низким частотам, назовем это трендовой составляющей ряда.

Таблица 5.8. MSE разложений ряда  $X = X_c + X_e + X_{\sin} + X_{\cos}$ 

Метод	Параметры	MSE( $X_c + X_e$ )	MSE( $X_{\sin}$ )	MSE( $X_{\cos}$ )	MSE( $X$ )
SSA	$L = 96, K = 96$	6.1e-05	8.9e-07	5.2e-05	2.1e-28
SSA	$L = 96, K = 97$	7.3e-05	4.2e-06	6.2e-05	1.1e-27
Fourier	$N = 96 \cdot 2$	1.1e-01	6.1e-04	6.8e-03	1.1e-01
Fourier	$N = 96 \cdot 2 - 1$	1.2e-01	1.9e-02	2.2e-02	1.0e-01
Fourier extended	$N = 96 \cdot 2$	1.4e-03	1.3e-03	8.4e-03	9.6e-03
Fourier extended	$N = 96 \cdot 2 - 1$	2.7e-03	3.1e-04	3.1e-03	5.9e-03
CiSSA	$L = 96$	5.3e-02	1.6e-05	4.9e-04	4.4e-02
CiSSA	$L = 97$	7.6e-02	4.1e-02	1.4e-02	1.1e-01
CiSSA extended	$L = 96$	5.0e-04	2.1e-04	1.1e-03	6.0e-04
CiSSA extended	$L = 97$	5.8e-04	1.3e-02	2.0e-03	1.4e-02
SSA EOSSA, $r = 6$	$L = 96, K = 96$	1.7e-28	1.6e-29	8.7e-30	1.6e-28
SSA EOSSA, $r = 6$	$L = 96, K = 97$	1.0e-27	2.3e-29	9.7e-30	9.5e-28

По таблице 5.8 видно, что алгоритмы CiSSA и Фурье без модификаций достаточно плохо определяют тренд. Ситуация с выделением тренда улучшается при использовании процедуры расширения ряда, однако есть недостаток у такого решения. В примерах, рассматривающихся для таблиц 5.5 и 5.8, можно заметить, что при применении расширения ряда ухудшается отделение периодических составляющих. Подобной проблемы нет с улучшением разделимости в методе SSA.

### 5.2.6. Отделение сигнала от шума

Рассмотрим влияние шума на результаты разделимости предыдущих примеров.

**Пример.** Вернемся к примеру из секции 5.2.3 и добавим к нему шум:  $X = X_{\sin} + X_{\cos} + X_{\text{noise}} = \sin \frac{2\pi}{12}n + \frac{1}{2} \cos \frac{2\pi}{3}n + \varepsilon_n$ , где  $\varepsilon_n \sim N(0, 0.1^2)$ . Кроме того, для всех алгоритмов кроме базового SSA выделялись периодические компоненты по диапазонам  $(\omega \pm \Delta)$ , где  $\Delta = \frac{1}{N+1}$ ,  $\omega = \frac{1}{12}, \frac{1}{3}$ . Проводилось 100 тестов, в таблице 5.9 указаны средние значения ошибки для одних и тех же реализаций шума.

Таблица 5.9. MSE разложений ряда  $X = X_{\sin} + X_{\cos} + X_{\text{noise}}$ 

Метод	Параметры	MSE( $X_{\sin}$ )	MSE( $X_{\cos}$ )	MSE( $X$ )
SSA	$L = 96, K = 96$	2.9e-04	3.1e-04	5.9e-04
SSA	$L = 96, K = 97$	2.9e-04	3.1e-04	5.9e-04
Fourier	$N = 96 \cdot 2$	1.0e-04	1.1e-04	2.2e-04
Fourier	$N = 96 \cdot 2 - 1$	1.8e-02	7.6e-03	2.6e-02
Fourier extended	$N = 96 \cdot 2$	1.2e-03	3.9e-03	5.1e-03
Fourier extended	$N = 96 \cdot 2 - 1$	1.2e-03	8.4e-04	2.0e-03
CiSSA	$L = 96$	1.6e-04	1.8e-04	3.4e-04
CiSSA	$L = 97$	4.1e-02	1.2e-02	5.2e-02
CiSSA extended	$L = 96$	6.6e-04	1.9e-03	2.5e-03
CiSSA extended	$L = 97$	1.4e-02	3.0e-03	1.7e-02
SSA EOSSA, $r = 4$	$L = 96, K = 96$	2.9e-04	3.1e-04	5.9e-04
SSA EOSSA, $r = 4$	$L = 96, K = 97$	2.9e-04	3.0e-04	5.9e-04

По таблице 5.9 видно, что зашумление ряда сильно повлияло на ошибку, теперь она не является машинным нулем ни для одного из методов. Также был проведен парный t-критерий для зависимых выборок с целью проверки гипотезы о равенстве средних значений ошибки для каждой компоненты, попарно для всех методов. В качестве нулевой гипотезы ( $H_0$ ) предполагалось, что средние значения двух сравниваемых выборок равны. Критический уровень значимости был установлен на уровне  $\alpha = 0.05$ . Результаты анализа показали, что во всех случаях, кроме сравнения SSA и SSA с EOSSA,  $p$ -значение оказалось меньше 0.05, что позволяет отвергнуть нулевую гипотезу.

**Пример.** Теперь вновь добавим трендовую составляющую к ряду:  $X = X_c + X_e + X_{\sin} + X_{\cos} + X_{\text{noise}} = 1 + e^{\frac{x}{100}} + \sin \frac{2\pi}{12}x + \frac{1}{2} \cos \frac{2\pi}{3}x + \varepsilon_n$ , где  $\varepsilon_n \sim N(0, 0.1^2)$ . Кроме того, для всех алгоритмов кроме базового SSA выделялись периодические компоненты по диапазонам  $(\omega \pm \Delta)$ , где  $\Delta = \frac{1}{N+1}$ ,  $\omega = \frac{1}{12}, \frac{1}{3}$ , а непериодичность соответствовала диапазону частот  $[0, \frac{1}{24})$ . Проводилось 100 тестов, в таблице 5.10 указаны средние значения ошибки для одних и тех же реализаций шума.

Таблица 5.10. MSE разложений ряда  $X = X_{\sin} + X_{\cos} + X_c + X_e + X_{\text{noise}}$  методов

Метод	Параметры	MSE( $X_c + X_e$ )	MSE( $X_{\sin}$ )	MSE( $X_{\cos}$ )	MSE( $X$ )
SSA	$L = 96, K = 96$	5.2e-03	2.9e-04	3.6e-04	5.2e-03
SSA	$L = 96, K = 97$	5.5e-03	2.9e-04	3.7e-04	5.3e-03
Fourier	$N = 96 \cdot 2$	1.2e-01	6.9e-04	7.2e-03	1.1e-01
Fourier	$N = 96 \cdot 2 - 1$	1.2e-01	1.9e-02	2.2e-02	1.0e-01
Fourier extended	$N = 96 \cdot 2$	3.0e-03	1.9e-03	9.6e-03	1.2e-02
Fourier extended	$N = 96 \cdot 2 - 1$	4.7e-03	8.6e-04	3.0e-03	7.8e-03
CiSSA	$L = 96$	5.5e-02	1.7e-04	7.0e-04	4.6e-02
CiSSA	$L = 97$	7.7e-02	4.1e-02	1.4e-02	1.1e-01
CiSSA extended	$L = 96$	2.7e-03	6.8e-04	2.1e-03	3.1e-03
CiSSA extended	$L = 97$	2.7e-03	1.4e-02	3.3e-03	1.7e-02
SSA EOSSA, $r = 6$	$L = 96, K = 96$	9.5e-04	2.9e-04	3.1e-04	1.5e-03
SSA EOSSA, $r = 6$	$L = 96, K = 97$	9.3e-04	2.9e-04	3.1e-04	1.5e-03

Как видно из таблицы 5.10, разделения ухудшились, однако SSA с улучшением разделимости EOSSA отработал лучше всех, а хуже всех показали себя алгоритмы Фурье. Также был проведен двухвыборочный t-критерий для зависимых выборок с целью проверки гипотезы о равенстве средних значений ошибки для каждой компоненты, попарно для всех методов. В качестве нулевой гипотезы ( $H_0$ ) предполагалось, что средние значения двух сравниваемых выборок равны. Критический уровень значимости был установлен на уровне  $\alpha = 0.05$ . Результаты анализа показали, что во всех случаях, кроме сравнения синуса для базового SSA и SSA с EOSSA, а также синуса для Фурье и расширенного CiSSA,  $p$ -значение оказалось меньше 0.05, что позволяет отвергнуть нулевую гипотезу.

Таким образом, можно сделать вывод, что алгоритмы отделяют сигнал от шума примерно одинаково, когда ряд состоит из периодик и параметры правильно подобраны. Результаты не сильно изменяются для базового SSA и SSA с EOSSA. Для CiSSA и Фурье результаты ухудшаются. С добавлением трендовой составляющей ситуация меняется:

для SSA результаты практически не ухудшаются, CiSSA с расширением показывает себя немного хуже SSA, остальные алгоритмы выдают значения ошибки на порядки большие.

### 5.2.7. Разделение трендовых составляющих между собой

Как удалось выяснить, все рассматриваемые алгоритмы могут выделять трендовую составляющую из ряда. Однако лишь SSA способен различить между собой две непериодических компоненты. Про скорость асимптотической разделимости для SSA можно подробнее узнать в книге [5]. Методы CiSSA и Фурье никаким образом не смогут отличить две непериодики между друг другом, поскольку они объединяют компоненты только по частотам. А двум непериодикам соответствуют одинаковые (низкие) наборы частот.

### 5.2.8. Преимущества и недостатки методов SSA, Фурье и CiSSA

Для наглядного отображения преимуществ каждого из этих методов составлены похожие по смыслу таблицы 5.11 и 5.12, где строки соответствуют методам, а столбцы — условиям (особым видам компонент ряда). Разделение на две таблицы объяснимо тем, что методам SSA и CiSSA важно, какие  $L$  и  $K$  выбраны у ряда, в то время как разложение Фурье волнует только  $N$ . На пересечении строк и столбцов указан знак, показывающий, достигается ли разделение компоненты: плюс (+) обозначает точное выполнение, знак стремления указывает на асимптотическое выполнение, а минус (−) — на отсутствие разделимости.

Обозначения:

- $\cos$  — в ряде присутствуют только периодические компоненты вида  $A \cos(2\pi\omega x + \varphi)$ ;
- $X_{np1}$  — одна непериодическая компонента в ряде, остальные имеют период;
- $X_{np}$  — несколько непериодических компонент в ряде, остальные имеют период, интересует разделение между непериодическими компонентами;
- $group$  — автоматическая группировка по заданным частотам.



Таблица 5.11. Преимущества и недостатки методов SSA, CiSSA

Метод/Условие	cos,	cos,	cos,	$X_{np1}$	$X_{np}$	group
	$Lw \in \mathbb{N}$ ,	$Lw \in \mathbb{N}$ ,	$Lw \notin \mathbb{N}$ ,			
	$Kw \in \mathbb{N}$	$Kw \notin \mathbb{N}$	$Kw \notin \mathbb{N}$			
SSA	+	$\rightarrow$	$\rightarrow$	$\rightarrow$	$\rightarrow$	—
SSA EOSSA	+	$\rightarrow$	$\rightarrow$	$\rightarrow$	$\rightarrow$	+
CiSSA	+	+	$\rightarrow$	—	—	+
CiSSA extended	+	+	$\rightarrow$	$\rightarrow$	—	+

Таблица 5.12. Преимущества и недостатки методов Fourier

Метод/Условие	cos,	cos,	$X_{np1}$	$X_{np}$	group
	$Nw \in \mathbb{N}$	$Nw \notin \mathbb{N}$			
Fourier	+	$\rightarrow$	—	—	+
Fourier extended	+	$\rightarrow$	$\rightarrow$	—	+

Большинство ситуаций из таблицы 5.11 и 5.12 уже были разобраны в предыдущих разделах. Так, столбцы, связанные с cos, были разобраны в разделах 5.2.3 и 5.2.4. Ситуация с одной непериодической компонентой разобрана в 5.2.5, а с отделением нескольких непериодик в 5.2.7. Автоматическая группировка компонент по заранее заданным частотам в 5.2.1.

Анализ полученных результатов показывает, что CiSSA превосходит разложение Фурье как с расширением ряда, так и без него, во всех случаях, когда интересующие частоты совпадают с частотной решеткой алгоритмов. Если же частоты не совпадают, разложение Фурье может дать лучший результат благодаря более детальному разбиению частот. Кроме того, SSA с улучшением делимости EOSSA продемонстрировал более высокую эффективность по сравнению со всеми ранее рассматриваемыми алгоритмами.

### 5.2.9. Проверка алгоритмов на реальных данных

Теперь рассмотрим реальные данные — месячные ряды промышленного производства (Industrial Production, IP), index 2010 = 100, в США. Данные промышленного производства полезны, поскольку оно указывается в определении рецессии Национальным бюро экономических исследований (NBER), как один из четырех ежемесячных рядов индикаторов, которые необходимо проверять при анализе делового цикла. Выборка охватывает период с января 1970 года по сентябрь 2014 года, поэтому размер выборки составляет  $N = 537$ . Источником данных является база данных IMF. Эти показатели демонстрируют различные тенденции, сезонность и цикличность (периодические компоненты, которые соответствуют циклам бизнеса). Данные IP также рассматривались в статье [1]. Применим как CiSSA с расширением ряда, так и SSA с автоматическим определением частот и улучшениями разделимости EOSSA и FOSSA с параметром  $r = 30$  по следующим группам:

1. Трендовой составляющей должны отвечать низкие частоты, поэтому диапазон:  $[0, \frac{1}{192}]$ ;
2. Циклы бизнеса по диапазонам:  $[\frac{2}{192}, \frac{10}{192}]$ ;
3. Сезонность по частотам  $\omega_k = 1/12, 1/6, 1/4, 1/3, 5/12, 1/2$ ;

На основе предыдущих требований взято  $L = 192$ .




Рис. 5.5. Трендовая составляющая данных IP USA

При применении FOSSA улучшения разделимости алгоритм **SSA** выделяет тренд довольно похож с **CiSSA**. Весь график **SSA** тренд **EOSSA** выглядит более изогнутым при визуальном сравнении с остальными.




Рис. 5.6. Циклическая составляющая данных IP USA

Аналогичная тренду ситуация происходит с цикличностью. В случае **EOSSA** пра-

вый хвост (значения ряда после 2010-ого года) смешался между цикличностью и трендом.




Рис. 5.7. Объединение тренда и цикличности IP USA

Как видно из графика 5.7, объединив тренд и цикличность получаем одинаковые результаты для всех рассматриваемых алгоритмов.

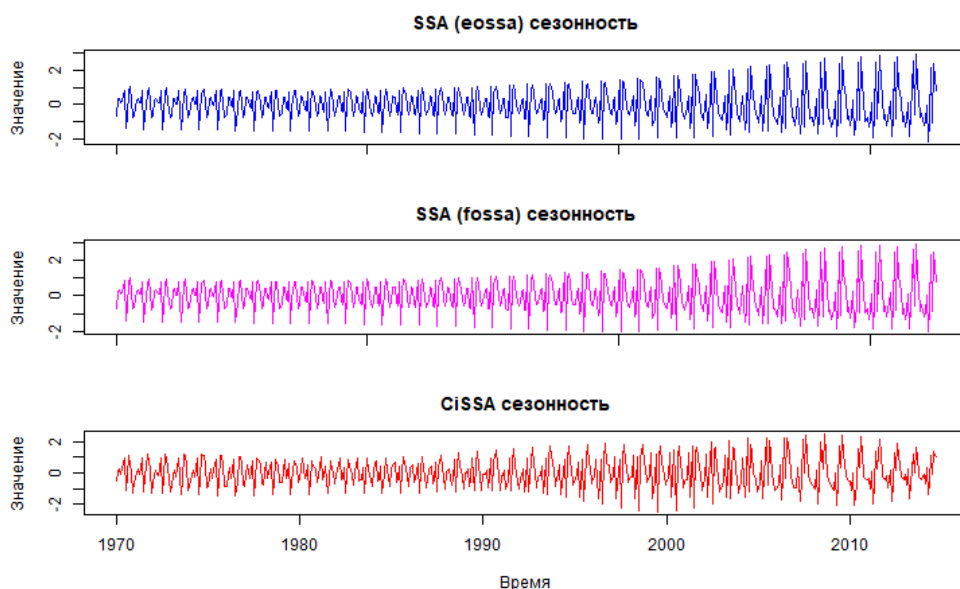


Рис. 5.8. Сезонная составляющая данных IP USA

Сезонность выглядит для всех алгоритмов похоже.

Шум же является нормальным во всех случаях.




Рис. 5.9. Матрицы корреляций IP USA

По матрицам корреляции заметно, что при использовании **SSA** с улучшением разделимости EOSSA, смешиваются первые по значимости компоненты ряда (они и являются трендовыми и циклическими).

Таким образом, получились довольно похожие результаты в выделении тренда и цикличности при использовании **SSA** с FOSSA и CiSSA. Несколько иные результаты при **SSA** с EOSSA.

### 5.3. Сравнение FSSA, MSSA, 2d-SSA

В оригинальной работе FSSA [10] рассматривалось сравнение алгоритма с dFPCA, MSSA. Однако, 2d-SSA в данном сравнении не было, хотя он может показать результаты лучше, чем MSSA, за счет того, что более гибко можно рассматривать зависимость по второй переменной.

#### 5.3.1. Численное сравнение

Рассматриваются функциональные временные ряды длины  $N = 50, 100, 150$  и  $200$ , наблюдаемые в  $n = 100$  фиксированных равноудаленных дискретных точках  $s$  на  $[0, 1]$  по следующей модели:

$$Y_t(s_i) = m_t(s_i) + X_t(s_i), \quad s_i \in [0, 1], i = 1, \dots, n, \text{ и } t = 1, \dots, N. \quad (5.1)$$

Для преобразования  $\{Y_t(s_i)\}$  в гладкие (непрерывные) функциональные кривые применяется кубическая В-сплайн базисная функция с 15 степенями свободы. В данной модели  $m_t(s)$  является периодической компонентой, определенной как

$$m_t(s) = e^{s^2} \cos(2\pi\omega t) + \cos(4\pi s) \sin(2\pi\omega t), \quad (5.2)$$

где  $\omega$  — частота модели с тремя значениями ( $\omega = 0, 0.1$  и  $0.25$ ).

В этом случае  $\{X_t(s_i), t = 1, \dots, N \text{ и } i = 1, \dots, n\}$  генерируется из независимого гауссовского белого шума (GWN) с нулевым средним и стандартным отклонением, равным 0.1.

Для сравнения производительности методов FSSA и MSSA рассматриваются три значения длины окна вдоль времени:  $L = 20, 30$  и  $40$ . Для 2d-SSA вдоль  $s$  длина окна равна 50. Также в алгоритмах MSSA и FSSA используются первые две собственные компоненты, а для 2d-SSA первые 8 собственных компонент. Разделения сравниваются по RMSE:

$$RMSE = \sqrt{\frac{1}{N \times n} \sum_{t=1}^N \sum_{i=1}^n \left( Y_t(s_i) - \hat{Y}_t(s_i) \right)^2},$$

где  $\hat{Y}_t(s_i)$  — функциональный временной ряд, реконструированный каждым методом. Эксперимент повторяется 100 раз, и считается среднее значение RMSE.

Таблица 5.13. Результаты сравнения методов 2d-SSA, MSSA и FSSA при различных параметрах  $\omega$  и  $N$

$\omega$	$N$	$L = 20$			$L = 30$			$L = 40$		
		2D-SSA	MSSA	FSSA	2D-SSA	MSSA	FSSA	2D-SSA	MSSA	FSSA
0.00	50	0.013	0.024	0.008	0.014	0.024	0.011	0.015	0.020	0.014
	100	0.009	0.023	0.007	0.009	0.021	0.007	0.009	0.017	0.007
	150	0.009	0.026	0.005	0.009	0.019	0.005	0.008	0.017	0.005
	200	0.009	0.027	0.006	0.008	0.020	0.005	0.007	0.017	0.005
0.10	50	0.009	0.028	0.009	0.010	0.026	0.010	0.011	0.021	0.013
	100	0.009	0.027	0.008	0.007	0.023	0.006	0.006	0.020	0.006
	150	0.008	0.027	0.005	0.007	0.023	0.006	0.006	0.019	0.005
	200	0.007	0.026	0.005	0.006	0.022	0.005	0.006	0.019	0.005
0.25	50	0.009	0.029	0.010	0.009	0.023	0.010	0.010	0.021	0.014
	100	0.008	0.027	0.006	0.008	0.024	0.007	0.006	0.020	0.007
	150	0.007	0.026	0.005	0.007	0.021	0.006	0.006	0.020	0.006
	200	0.008	0.026	0.005	0.007	0.022	0.005	0.006	0.019	0.005

По результатам таблицы 5.13 можно сказать, что **FSSA** действительно чаще справляется лучше в данной модели, чем **2d-SSA** и **MSSA**. Однако **2d-SSA** показывает тот же порядок ошибки, что и **FSSA**, разница несущественна. **2d-SSA** в свою очередь показывает более хорошие результаты, в отличие от **MSSA**.

## Заключение

В данной работе исследованы алгоритмы **SSA**, **GSSA** и **CiSSA**, а также многомерные модификации: **MSSA**, **2d-SSA**, **FSSA**. Проведено их сравнение теоретически, и полученные знания были проверены на реальных и смоделированных примерах с помощью языка **R**. Найдены недостатки и достоинства алгоритмов.

Алгоритм **GSSA** в сравнении с **SSA** лучше справляется с разделимостью компонент между друг другом. Однако это справедливо только тогда, когда в ряде нет шума. Метод **SSA** лучше будет справляться с задачей выделения сигнала.

При сравнении **CiSSA** и **SSA** также выяснилось, что **CiSSA** выделяет трендовую компоненту лучше, чем разложение Фурье, однако проигрывает в выделении периодик, особенно когда частота выделяемой компоненты не попадает в сетку частот методов.

Рассматривая **SSA** с улучшением разделимости и **CiSSA** на модельных примерах, видно, что по среднеквадратической ошибке **SSA** выигрывает у **CiSSA**. Кроме того, алгоритм **SSA** является более гибким: в нем адаптивный базис, есть дополнительные алгоритмы, которые довольно похоже приближают этот алгоритм к **CiSSA**, а также методы для автоматического выбора компонентов по частотам. Метод **CiSSA** является простым в использовании.

Алгоритм **FSSA** показывает численное преимущество над алгоритмами **MSSA** и **2d-SSA**.

Дальнейшими действиями является детальное сравнение алгоритмов **MSSA**, **2d-SSA** и **FSSA**.



## Список литературы

1. Juan Bogalo, Pilar Poncela, and Eva Senra. Circulant singular spectrum analysis: A new automated procedure for signal extraction. *Signal Processing*, 177, 2020.
2. Rahul Dey, Meloth Thamban, Chavarukonam Madhavanpillai Laluraj, Kanthanathan Mahalinganathan, Bhikaji Laxman Redkar, Sudhir Kumar, and Kenichi Matsuoka. Application of visual stratigraphy from line-scan images to constrain chronology and melt features of a firn core from coastal antarctica. *Journal of Glaciology*, 69(273):179–190, 2023.
3. Nina Golyandina, Pavel Dudnik, and Alex Shlemov. Intelligent identification of trend components in singular spectrum analysis. *Algorithms*, 16(7):353, 2023.
4. Nina Golyandina, Anton Korobeynikov, and Anatoly Zhigljavsky. *Singular Spectrum Analysis with R*. 01 2018.
5. Nina Golyandina, Vladimir Nekrutkin, and Anatoly Zhigljavsky. *Analysis of Time Series Structure: SSA and Related Techniques*. Chapman and Hall/CRC, 2001.
6. Nina Golyandina and Alex Shlemov. Variations of singular spectrum analysis for separability improvement: non-orthogonal decompositions of time series. *Statistics and Its Interface*, 8(3):277–294, 2015.
7. Nina Golyandina and Anatoly Zhigljavsky. *Singular Spectrum Analysis for Time Series*. SpringerBriefs in Statistics. Springer Berlin Heidelberg, 2 edition, 2020.
8. Nina Golyandina and Polina Zhornikova. On automated identification in singular spectrum analysis for different types of objects, 2023.
9. Jialiang Gu, Kevin Hung, Bingo Wing-Kuen Ling, Daniel Hung-Kay Chow, Yang Zhou, Yaru Fu, and Sio Hang Pun. Generalized singular spectrum analysis for the decomposition and analysis of non-stationary signals. *Journal of the Franklin Institute*, Accepted/In Press, 2024.
10. Hossein Haghbin, Seyed Morteza Najibi, Rahim Mahmoudvand, Jordan Trinka, and Mehdi Maadooliat. Functional singular spectrum analysis, 2019.
11. Nikolay Pogrebnikov. SPbSU SSA coursework: Time series analysis. [https://github.com/xSICHx/spbu\\_ssa\\_methods\\_coursework/tree/main](https://github.com/xSICHx/spbu_ssa_methods_coursework/tree/main), 2024.

12. E.W. Weisstein. *CRC Concise Encyclopedia of Mathematics*. CRC Press, 2002.
13. Jammisetty Yedukondalu, Kalyani Sunkara, Vankayalapati Radhika, Sivakrishna Kondaveeti, Murali Anumothu, and Yadadavalli Krishna. Cognitive load detection through eeg lead wise feature optimization and ensemble classification. *Scientific Reports*, 15, 01 2025.